

4. Hafta - Proje Taslağı ve Veri Setinin Belirlenmesi

March 8, 2025

0.1 4. Hafta: Proje Taslağı ve Veri Setinin Belirlenmesi

1.1. Projenin amaç ve kapsamının belirlenmesi

1.2. Kullanılacak veri setinin seçimi ve veri kaynağının belirlenmesi

1.3. Veri setinin genel yapısının incelenmesi

- Veriyi yükleme: CSV, Excel, JSON vb. gibi farklı formatlardaki verinin içe aktarılması

0.1.1 1.1. Projenin amaç ve kapsamının belirlenmesi

Proje Konusu ve Amacı:

Farklı makine öğrenmesi yöntemlerinin sınıflandırma problemleri üzerindeki performanslarını karşılaştırmayı amaçlamaktadır. Projede çeşitli veri ön işleme adımları, özellik mühendisliği ve farklı algoritmalar kullanılarak modeller eğitilecek, sonuçlar analiz edilip ve karşılaştırılmasını hedefler.

0.1.2 1.2. Kullanılacak veri setinin seçimi ve veri kaynağının belirlenmesi

Bu projede, UCI Machine Learning Repository üzerinden sağlanan “Bank Marketing” veri seti kullanılmıştır. Bu veri seti, Portekiz’deki bir bankanın doğrudan pazarlama kampanyalarının verilerini içermektedir ve müşteriyle yapılan telefon görüşmelerinin kampanya başarısı üzerindeki etkisini analiz etmeyi amaçlamaktadır.

Veri Kaynağı ve Açıklaması

Kaynak: UCI Machine Learning Repository Bağlantı: <https://archive.ics.uci.edu/dataset/222/bank+marketing>

Veri Kümesi İçeriği: - Müşterilere ait demografik bilgiler (yaş, iş durumu, medeni hal vb.). - Bankacılık bilgileri (mevduat durumu, kredi kartı kullanımı vb.). - Kampanya detayları (görüşme süresi, çağrı sonucu, kampanyaya dahil olma durumu vb.). - Ekonomik göstergeler (işsizlik oranı, faiz oranı vb.). - Hedef değişken: Müşterinin bankanın vadeli mevduat teklifini kabul edip etmediği (binary classification: “yes” veya “no”).

Bu Veri Setinin Seçilme Nedenleri

Bu veri seti, sınıflandırma problemleri için oldukça uygun bir yapıdadır. Seçim kriterlerimiz şu şekildedir:

1. Gerçek Dünya Verisi Olması

- Gerçek bir bankacılık sektörüne ait olup, pazarlama kampanyalarının etkinliğini değerlendirmek için kullanılan bir veri kümesidir.
- Müşteri davranışlarını analiz etmek, iş dünyasında uygulanabilir bir model oluşturmak için anlamlıdır.

2. Sınıflandırma Problemlerine Uygunluk

- Bu proje kapsamında farklı makine öğrenmesi yöntemlerini karşılaştırarak en iyi modeli belirleme hedeflenmektedir.
- Veri seti, ikili sınıflandırma problemi içerdiğinden (müşterinin kampanyaya katılımı “yes/no”), farklı sınıflandırma algoritmalarını karşılaştırmak için uygundur.

3. Çeşitli Özellikler İçermesi

- Hem sayısal hem de kategorik değişkenlerden oluştuğu için özellik mühendisliği ve veri ön işleme adımlarını uygulamak açısından zengin bir veri setidir.
- Ekonomik göstergeler, müşteri bilgileri ve pazarlama stratejileri gibi çok boyutlu veriler barındırması, modelleme sürecini güçlendirmektedir.

4. Akademik ve Endüstriyel Kullanım Alanı

- Veri seti, makine öğrenmesi alanında birçok araştırmada ve iş dünyasında müşteri analitiği konusunda yaygın olarak kullanılmaktadır.
- Pazarlama stratejilerini geliştirmek, müşteri segmentasyonu yapmak ve kampanya başarı oranlarını artırmak için kullanılan bir veri setidir.

0.1.3 1.3. Veri setinin genel yapısının incelenmesi

- Veriyi yükleme: CSV, Excel, JSON vb. gibi farklı formatlardaki verinin içe aktarılması

```
[1]: # Kullanacağımız kütüphaneleri yükleyelim.
```

```
# Pandas ve NumPy
import pandas as pd
import numpy as np

# Görselleştirme kütüphaneleri
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[2]: # Veri setini notebook içerisine dahil edelim.
```

```
# df = pd.read_csv("bank-additional-full.csv")

df = pd.read_csv("bank-full.csv", sep=";")
```

```
[3]: df
```

```
[3]:
```

	age	job	marital	education	default	balance	housing	loan	\
0	58	management	married	tertiary	no	2143	yes	no	
1	44	technician	single	secondary	no	29	yes	no	

2	33	entrepreneur	married	secondary	no	2	yes	yes	
3	47	blue-collar	married	unknown	no	1506	yes	no	
4	33	unknown	single	unknown	no	1	no	no	
...	...	...	...	...	...	...	...	...	
45206	51	technician	married	tertiary	no	825	no	no	
45207	71	retired	divorced	primary	no	1729	no	no	
45208	72	retired	married	secondary	no	5715	no	no	
45209	57	blue-collar	married	secondary	no	668	no	no	
45210	37	entrepreneur	married	secondary	no	2971	no	no	
		contact	day month	duration	campaign	pdays	previous	poutcome	y
0		unknown	5 may	261	1	-1	0	unknown	no
1		unknown	5 may	151	1	-1	0	unknown	no
2		unknown	5 may	76	1	-1	0	unknown	no
3		unknown	5 may	92	1	-1	0	unknown	no
4		unknown	5 may	198	1	-1	0	unknown	no
...	...	...	...	...	...	...	...	...	...
45206		cellular	17 nov	977	3	-1	0	unknown	yes
45207		cellular	17 nov	456	2	-1	0	unknown	yes
45208		cellular	17 nov	1127	5	184	3	success	yes
45209		telephone	17 nov	508	4	-1	0	unknown	no
45210		cellular	17 nov	361	2	188	11	other	no

[45211 rows x 17 columns]

Veri setimiz 45211 gözlem ve 17 column içermektedir.

Column'ları tek tek daha net açıklayalım.

1. age (Yaş)

- Müşterinin yaşı (Sayısal bir değer).

2. job (Meslek)

- Müşterinin mesleği (Kategorik değişken):
 - 'admin.' (Yönetici)
 - 'blue-collar' (Mavi yakalı)
 - 'entrepreneur' (Girişimci)
 - 'housemaid' (Hizmetçi)
 - 'management' (Üst düzey yönetici)
 - 'retired' (Emekli)
 - 'self-employed' (Serbest meslek sahibi)
 - 'services' (Hizmet sektörü çalışanı)
 - 'student' (Öğrenci)
 - 'technician' (Teknisyen)
 - 'unemployed' (İşsiz)
 - 'unknown' (Bilinmeyen)

3. marital (Medeni Durum)

- Müşterinin medeni durumu (Kategorik değişken):
 - ‘married’ (Evli)
 - ‘single’ (Bekar)
 - ‘divorced’ (Boşanmış - note: ‘divorced’ means divorced or widowed (dul))
 - ‘unknown’ (Bilinmeyen)
- 4. education (Eğitim Durumu)
 - Müşterinin eğitim seviyesi (Kategorik değişken):
 - ‘primary’ (İlkokul)
 - ‘secondary’ (Ortaokul/lise)
 - ‘tertiary’ (Üniversite veya daha yüksek)
 - ‘unknown’ (Bilinmeyen)
- 5. default (Kredi Temerrüdü)
 - Müşterinin bankaya olan geçmiş kredi borcunu ödeyememe durumu (İkili değişken):
 - ‘yes’ (Evet)
 - ‘no’ (Hayır)
- 6. balance (Bakiye)
 - Müşterinin bankadaki hesap bakiyesi (Sayısal değer, euro cinsinden).
- 7. housing (Konut Kredisi)
 - Müşterinin bir konut kredisine sahip olup olmadığı (İkili değişken):
 - ‘yes’ (Evet)
 - ‘no’ (Hayır)
- 8. loan (Kişisel Kredi)
 - Müşterinin kişisel krediye sahip olup olmadığı (İkili değişken):
 - ‘yes’ (Evet)
 - ‘no’ (Hayır)
- 9. contact (İletişim Türü)
 - Bankanın müşteri ile hangi iletişim yöntemini kullandığı (Kategorik değişken):
 - ‘cellular’ (Cep telefonu)
 - ‘telephone’ (Sabit telefon)
 - ‘unknown’ (Bilinmeyen)
- 10. day (Son İletişim Günü)
 - Bankanın müşteri ile en son iletişime geçtiği gün (Sayısal değişken, 1-31 arası).
- 11. month (Son İletişim Ayı)
 - Bankanın müşteri ile en son iletişime geçtiği ay (Kategorik değişken):
 - ‘jan’ (Ocak)
 - ‘feb’ (Şubat)
 - ‘mar’ (Mart)
 - ‘apr’ (Nisan)
 - ‘may’ (Mayıs)
 - ‘jun’ (Haziran)

- ‘jul’ (Temmuz)
 - ‘aug’ (Ağustos)
 - ‘sep’ (Eylül)
 - ‘oct’ (Ekim)
 - ‘nov’ (Kasım)
 - ‘dec’ (Aralık)
12. duration (İletişim Süresi)
- Son yapılan çağrının süresi, saniye cinsinden (Sayısal değişken).
 - Not: Bu değişken model eğitimi için doğrudan kullanılmamalıdır, çünkü tahmin sürecinde bilinemez.
13. campaign (İletişim Sayısı)
- Bu kampanya sırasında müşteri ile kaç kez iletişim kurulduğu (Sayısal değişken).
14. pdays (Önceki Kampanyadan Sonraki Gün Sayısı)
- Müşteriyle önceki pazarlama kampanyasından kaç gün sonra tekrar iletişime geçildiği (Sayısal değişken).
 - 999 değeri, müşterinin önceki kampanyada iletişim almadığını gösterir.
 - (numeric; -1 means client was not previously contacted)
15. previous (Önceki Kampanyada Yapılan İletişim Sayısı)
- Müşteriyle önceki pazarlama kampanyası sırasında kaç kez iletişim kurulduğu (Sayısal değişken).
16. poutcome (Önceki Kampanya Sonucu)
- Müşterinin önceki kampanyaya verdiği yanıt (Kategorik değişken):
 - ‘failure’ (Başarısız)
 - ‘success’ (Başarılı)
 - ‘other’ (Diğer)
 - ‘unknown’ (Bilinmeyen)
17. y (Hedef Değişken - Mevduat Aboneliği)
- Müşterinin kampanya sonucunda bankanın vadeli mevduat ürününü alıp almadığı (Bağımlı değişken):
 - ‘yes’ (Evet, ürün satın alındı)
 - ‘no’ (Hayır, ürün satın alınmadı)