

## 5. Hafta - Veri Keşfetme (Exploratory Data Analysis - EDA)

April 1, 2025

### 1 5. Hafta: Veri Keşfetme (Exploratory Data Analysis - EDA)

#### 2.1.Keşifçi Veri Analizi (EDA) yapılması

- Veriyi inceleme: `head()`, `info()`, `describe()` vb. metotlarla veri yapısının incelenmesi

2.2.Gerekli görsel analizlerin gerçekleştirilmesi (veriyi daha yakından tanımak amacıyla)

2.3.Cevaplanması gereken soruların belirlenmesi, yorumlanması ve gerekli olması durumunda görselleştirilmesi

#### 1.0.1 2.1.Keşifçi Veri Analizi (EDA) yapılması

- Veriyi inceleme: `head()`, `info()`, `describe()` vb. metotlarla veri yapısının incelenmesi

```
[136]: # Kullanacağımız kütüphaneleri yükleyelim.
```

```
# Pandas ve NumPy
import pandas as pd
import numpy as np
import seaborn as sns

# Görselleştirme kütüphaneleri
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[137]: # Veri setini notebook içerisine dahil edelim.
```

```
# df = pd.read_csv("bank-additional-full.csv")

df = pd.read_csv("bank-full.csv", sep=";")
```

1.0.2 `.head()` baştan 5 değeri getirir - default değeri 5'tir.

```
[138]: df.head()
```

```
[138]: age          job marital education default balance housing loan \
0    58    management married   tertiary      no      2143      yes   no
1    44    technician single    secondary      no        29      yes   no
2    33  entrepreneur married    secondary      no         2      yes  yes
3    47  blue-collar married    unknown       no      1506      yes   no
4    33      unknown single     unknown       no         1      no   no

      contact day month duration campaign pdays previous poutcome y
0  unknown    5   may      261         1     -1         0  unknown  no
1  unknown    5   may      151         1     -1         0  unknown  no
2  unknown    5   may       76         1     -1         0  unknown  no
3  unknown    5   may       92         1     -1         0  unknown  no
4  unknown    5   may      198         1     -1         0  unknown  no
```

1.0.3 .tail() sondan 5 değeri getirir - default değeri 5'tir.

```
[139]: df.tail()
```

```
[139]: age          job marital education default balance housing loan \
45206  51    technician married   tertiary      no       825      no   no
45207  71      retired divorced   primary      no      1729      no   no
45208  72      retired married    secondary      no      5715      no   no
45209  57  blue-collar married    secondary      no       668      no   no
45210  37  entrepreneur married    secondary      no      2971      no   no

      contact day month duration campaign pdays previous poutcome y
45206  cellular  17   nov       977         3     -1         0  unknown  yes
45207  cellular  17   nov       456         2     -1         0  unknown  yes
45208  cellular  17   nov      1127         5     184         3  success  yes
45209  telephone 17   nov       508         4     -1         0  unknown  no
45210  cellular  17   nov       361         2     188        11   other   no
```

1.0.4 type() değişken tipini döndürür.

```
[140]: type(df)
```

```
[140]: pandas.core.frame.DataFrame
```

1.0.5 .dtypes ile veri setindeki değişkenleri ve değişken tiplerini görüntüleyelim.

```
[141]: df.dtypes
```

```
[141]: age          int64
job          object
marital      object
education    object
default      object
```

```

balance      int64
housing      object
loan         object
contact      object
day          int64
month        object
duration     int64
campaign     int64
pdays       int64
previous     int64
poutcome     object
y            object
dtype: object

```

**1.0.6** `.shape` satır ve sütun bilgilerinin boyutunu döndürür. (satır, sütun)

```
[142]: df.shape
```

```
[142]: (45211, 17)
```

**1.0.7** `.columns` veri setinin değişkenlerini/ columnlarını getirir.

```
[143]: df.columns
```

```
[143]: Index(['age', 'job', 'marital', 'education', 'default', 'balance', 'housing',
            'loan', 'contact', 'day', 'month', 'duration', 'campaign', 'pdays',
            'previous', 'poutcome', 'y'],
            dtype='object')
```

**1.0.8** `.info()` ile veri hakkında daha detaylı bilgi içerir.

```
[144]: df.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column      Non-Null Count  Dtype
---  -
 0   age         45211 non-null  int64
 1   job         45211 non-null  object
 2   marital     45211 non-null  object
 3   education   45211 non-null  object
 4   default     45211 non-null  object
 5   balance     45211 non-null  int64
 6   housing     45211 non-null  object
 7   loan        45211 non-null  object
 8   contact     45211 non-null  object
 9   day         45211 non-null  int64

```

```
10 month      45211 non-null object
11 duration    45211 non-null int64
12 campaign    45211 non-null int64
13 pdays       45211 non-null int64
14 previous    45211 non-null int64
15 poutcome    45211 non-null object
16 y           45211 non-null object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
```

### Yorumlayalım:

- 45211 toplam gözlem sayısı bulunuyor.
- Veri 17 feature içermektedir.
- 7 int64 tipinde, 10 objects tipinde verimiz bulunmaktadır
- Veri içerisinde null değerler bulunmamaktadır.

```
[145]: df.isnull().values.any() # eksik değer var mı yok mu onu soruyoruz
```

```
[145]: False
```

**Yorumlayalım:** - Veri setimizde eksik değer bulunmamaktadır.

- Bank Marketing veri setinin açıklamalarına göre, “unknown” değerleri eksik veri olarak kabul edilmemektedir. Veri setinin “Eksik Değerler Var mı?” (Has Missing Values?) kısmında “Hayır” (No) ifadesi yer almaktadır.
- Bu durum, “unknown” olarak belirtilen değerlerin, eksik veri yerine, belirli özelliklerin (örneğin, müşterinin mesleği veya eğitim durumu) bilinmediğini veya kaydedilmediğini gösteren bir kategori olduğunu göstermektedir. Bu nedenle, “unknown” değerleri eksik veri olarak değil, mevcut verinin bir parçası olarak değerlendirilmelidir.
- Peki burada unknown değerleri silmek mi?, doldurmak mı? yoksa ayrı bir kategori olarak değerlendirmek mi gerekir?
  - İlerideki adımlarda her bir sütunda yer alan unknown değerlerinin oranına bakılarak bazı sütunlardaki unknown değerlerinin veriden çıkarılması(ileride makine öğrenmesi yaparken sorun çıkarmaması adına) veya bazı sütunlardaki unknown değerlerinin ayrı bir kategori olarak değerlendirilmesine karar verilmiştir.

**Veri setinin çerçevesindeki sütunları veri türlerine göre ayıralım.**

**Kategorik sütunları cat\_cols listesine, sayısal sütunları num\_cols listesine yerleştirelim.**

```
[146]: cat_cols = []
num_cols = []
cat_cols = [col for col in df.columns if str(df[col].dtypes) in ["category", "object", "bool", "datetime64[ns]"]]
num_cols = [col for col in df.columns if df[col].dtypes in ["int64", "float64"]]
```


```
[147]: cat_cols, num_cols
```

```
[147]: (['job',  
        'marital',  
        'education',  
        'default',  
        'housing',  
        'loan',  
        'contact',  
        'month',  
        'poutcome',  
        'y'],  
        ['age', 'balance', 'day', 'duration', 'campaign', 'pdays', 'previous'])
```

### Kategorik değişkenlerin incelenmesi ve görselleştirilmesi

```
[148]: def bar_plot(variable):  
        # get feature  
        # var = df[variable]  
  
        var = df[variable].astype("category")  
  
        # count number of categorical variable(value/sample)  
        varValue = var.value_counts()  
  
        # visualize  
        plt.figure(figsize = (9,3))  
        plt.bar(varValue.index, varValue)  
        plt.xticks(varValue.index, varValue.index.values, rotation=60)  
        plt.ylabel("Frequency")  
        plt.grid(axis="y")  
        plt.title(variable)  
        plt.show()  
  
        print("{}: \n{}".format(variable,varValue))
```


```
[149]: for c in cat_cols:  
        bar_plot(c)
```




```

job:
blue-collar      9732
management      9458
technician      7597
admin.          5171
services        4154
retired         2264
self-employed   1579
entrepreneur    1487
unemployed      1303
housemaid       1240
student         938
unknown         288
Name: job, dtype: int64


```



```
marital:
married      27214
single      12790
divorced     5207
Name: marital, dtype: int64
```




```
education:
secondary    23202
tertiary     13301
primary       6851
unknown       1857
Name: education, dtype: int64
```




```
default:
```

```
no      44396
yes       815
Name: default, dtype: int64
```




```
housing:
yes      25130
no       20081
Name: housing, dtype: int64
```




```
loan:
no      37967
yes       724
Name: loan, dtype: int64
```






```
contact:
cellular    29285
unknown     13020
telephone    2906
Name: contact, dtype: int64
```




```
month:
may    13766
jul     6895
aug     6247
jun     5341
nov     3970
apr     2932
feb     2649
jan     1403
```

```
oct      738
sep      579
mar      477
dec      214
Name: month, dtype: int64
```



```
poutcome:
unknown    36959
failure     4901
other       1840
success     1511
Name: poutcome, dtype: int64
```



```
y:
no      39922
yes      5289
```

Name: y, dtype: int64

### Kategorik değişkenlerin yorumlanması

- job:
  - blue-collar = 9732 değeri ile en çok bulunan değerdir.
  - unknown = 288 değeri en az bulunan değerdir. (unknown veriler ile ne yapılacağı SONUÇ kısmında açıklanmıştır.)
  - Açıklama: Bankanın pazarlama kampanyalarını en çok ulaşılan meslek grubu beyaz yakalılarıdır.
- marital:
  - married = 27214 değeri ile en çok bulunan değerdir.
  - divorced = 5207 değeri en az bulunan değerdir.
  - Açıklama: Evli kişilere banka pazarlama kampanyaları için daha çok ulaşılmıştır.
- education:
  - secondary = 23202 değeri en çok bulunan değerdir.
  - unknown = 1857 değeri en az bulunan değerdir. (unknown veriler ile ne yapılacağı SONUÇ kısmında açıklanmıştır.)
  - Açıklama: Ortaokul/ lise eğitim seviyesinde bulunan kişilere daha çok ulaşılmıştır. Sebebi bu yaşlardaki genç kesimi bankaya kazandırmak olabilir.
- default:
  - no = 44396 değeri en çok bulunan değerdir.
  - yes = 815 değeri en az bulunan değerdir.
  - Açıklama: Bankaya kredi borcunu ödeyen kişilere daha çok ulaşılmıştır. Sebebi bu kişilerin daha güvenirli olmalarıdır.
- housing:
  - yes = 25130 değeri en çok bulunan değerdir.
  - no = 20081 değeri en az bulunan değerdir.
  - Açıklama: Konut kredisine sahip olan kişilere daha çok ulaşılmıştır. Sebebi zaten hali hazırda banka ile ilişkisi bulunduğu için olabilir.
- loan:
  - no = 37967 değeri en çok bulunan değerdir.
  - yes = 7244 değeri en az bulunan değerdir.
  - Açıklama: Kişisel krediye sahip olmayan kişilere daha çok ulaşılmıştır. Sebebi bu kişileri bankaya kazandırmaktır.
- contact:
  - cellular = 29285 değeri en çok bulunan değerdir.
  - unknown = 13020 değeri (unknown veriler ile ne yapılacağı SONUÇ kısmında açıklanmıştır.)
  - telephone = 2906 değeri en az bulunan değerdir.
  - Açıklama: Banka genelde müşterilere kişilerin cep telefonu üzerinden ulaşmış ve kampanya pazarlama tanıtımı yapmıştır.
- month:
  - may = 13766 değeri en çok bulunan değerdir.
  - dec = 214 değeri en az bulunan değerdir.
  - Açıklama: Banka pazarlama kampanyası en çok mayıs ayında, en az aralık ayında yapılmıştır.
- poutcome:
  - unknown = 36959 değeri en çok bulunan değerdir. (unknown veriler ile ne yapılacağı

SONUÇ kısmında açıklanmıştır.)

- success = 1511 değeri en az bulunan değerdir.
- Açıklama: Önceki kampanya sonucu en çok olan kişiler bilinmemektedir. Bunun sebebi verilerin girilmemiş olması olabilir. Önceki kampanyadan dönüş alıp başarılı olunan kişi sayısı en az olan kişiler = 1511 kişidir.

## SONUÇ:

unknown değeri içeren değişkenler için yorum:

- job ( ~ %0,5 ) (unknown oranları)
  - job = 288 unknown değeri bulunmaktadır.
  - Öneri: Bu sütunlarda “unknown” değerleri azınlıktadır. Bu nedenle, “unknown” değerlerini mevcut verilerle doldurabilir veya bu satırları analizden çıkarabilirsiniz.
- contact ( ~ %28 ) (unknown oranları)
  - contact = 13020 unknown değeri bulunmaktadır.
  - Öneri: Bu sütunda “unknown” değerleri fazladır. Bu nedenle, “unknown” değerini ayrı bir kategori olarak tutmak veya bu sütunu analizden tamamen çıkarmak daha mantıklı olabilir.
- education ( ~ %4 ) (unknown oranları)
  - education = 1857 unknown değeri bulunmaktadır.
  - Öneri: Bu durumda, “unknown” değerlerini en yaygın kategoriyle doldurabilir veya bu satırları analizden çıkarabilirsiniz.
- Örnek: poutcome ( ~ %80 )
  - poutcome = 36959 unknown değeri bulunmaktadır.
  - Öneri: Bu sütunda “unknown” değerleri baskındır. Bu nedenle, “unknown” değerini ayrı bir kategori olarak tutmak veya bu sütunu analizden tamamen çıkarmak daha mantıklı olabilir.

**1.0.9 Sonuç olarak, her sütun için “unknown” değerlerinin oranını dikkate alarak uygun bir strateji belirlemelidir. Bu değerleri ayrı bir kategori olarak tutmak daha uygun olacaktır. Bu sebeple:**

- **job, education, contact, poutcome** sütunundaki unknown değerlerini ayrı bir kategori olarak değerlendirilecektir. Veriden çıkarılmayacaktır.

## Numeric değişkenlerin incelenmesi ve görselleştirilmesi

```
[150]: import matplotlib.pyplot as plt

# Tüm sayısal sütunlar için histogram çizen fonksiyon
def plot_hist(df, column):
    plt.figure(figsize=(9, 3))

    # Histogram
    ax = df[column].hist(bins=16, edgecolor="black", alpha=0.7)
```

```

plt.xlabel(column)
plt.ylabel("Frequency")
plt.title(f"{column} Distribution")

# Mean ve median çizgilerini ekleme
mean_val = df[column].mean()
median_val = df[column].median()

plt.axvline(mean_val, color='blue', linestyle='--', label=f'Mean: {mean_val:
↪.2f}')
plt.axvline(median_val, color='red', linestyle='-', label=f'Median:␣
↪{median_val:.2f}')

# Değerlerin frekanslarını yazdır
value_counts = df[column].value_counts().sort_index()
print(f"---{column} Value Counts ---\n", value_counts)

print("")
print(f"EN ÇOK TEKRAR EDEN --- {column} --- DEĞERİ")
print(df[column].value_counts().head(1)) # En çok tekrar eden değeri␣
↪yazdırır

# Grafik etrafına çizgiyi ekle
plt.grid(True)
plt.legend(loc='upper right')

plt.show()

# Tüm sayısal değişkenler için fonksiyonu çalıştır
for col in num_cols:
    plot_hist(df, col)

```

```
---age Value Counts ---
```

```


18      12
19      35
20      50
21      79
22     129
...
90       2
92       2
93       2
94       1
95       2

```

```
Name: age, Length: 77, dtype: int64
```

```
EN ÇOK TEKRAR EDEN --- age --- DEĞERİ
```

32 2085  
Name: age, dtype: int64



---balance Value Counts ---


|        |   |
|--------|---|
| -8019  | 1 |
| -6847  | 1 |
| -4057  | 1 |
| -3372  | 1 |
| -3313  | 1 |
| ..     |   |
| 66721  | 1 |
| 71188  | 1 |
| 81204  | 2 |
| 98417  | 1 |
| 102127 | 1 |

Name: balance, Length: 7168, dtype: int64

EN ÇOK TEKRAR EDEN --- balance --- DEĞERİ

0 3514

Name: balance, dtype: int64



---day Value Counts ---


|    |      |
|----|------|
| 1  | 322  |
| 2  | 1293 |
| 3  | 1079 |
| 4  | 1445 |
| 5  | 1910 |
| 6  | 1932 |
| 7  | 1817 |
| 8  | 1842 |
| 9  | 1561 |
| 10 | 524  |
| 11 | 1479 |
| 12 | 1603 |
| 13 | 1585 |
| 14 | 1848 |
| 15 | 1703 |
| 16 | 1415 |
| 17 | 1939 |
| 18 | 2308 |
| 19 | 1757 |
| 20 | 2752 |
| 21 | 2026 |
| 22 | 905  |
| 23 | 939  |
| 24 | 447  |
| 25 | 840  |
| 26 | 1035 |
| 27 | 1121 |
| 28 | 1830 |
| 29 | 1745 |
| 30 | 1566 |
| 31 | 643  |

Name: day, dtype: int64

EN ÇOK TEKRAR EDEN --- day --- DEĞERİ

20 2752

Name: day, dtype: int64



---duration Value Counts ---

0 3

1 2

2 3

3 4

4 15

..

3366 1

3422 1

3785 1

3881 1

4918 1


Name: duration, Length: 1573, dtype: int64

EN ÇOK TEKRAR EDEN --- duration --- DEĞERİ

124 188

Name: duration, dtype: int64





---campaign Value Counts ---

|    |       |
|----|-------|
| 1  | 17544 |
| 2  | 12505 |
| 3  | 5521  |
| 4  | 3522  |
| 5  | 1764  |
| 6  | 1291  |
| 7  | 735   |
| 8  | 540   |
| 9  | 327   |
| 10 | 266   |
| 11 | 201   |
| 12 | 155   |
| 13 | 133   |
| 14 | 93    |
| 15 | 84    |
| 16 | 79    |
| 17 | 69    |
| 18 | 51    |
| 19 | 44    |
| 20 | 43    |
| 21 | 35    |
| 22 | 23    |
| 23 | 22    |
| 24 | 20    |
| 25 | 22    |
| 26 | 13    |
| 27 | 10    |
| 28 | 16    |
| 29 | 16    |
| 30 | 8     |
| 31 | 12    |

```

32      9
33      6
34      5
35      4
36      4
37      2
38      3
39      1
41      2
43      3
44      1
46      1
50      2
51      1
55      1
58      1
63      1


```

Name: campaign, dtype: int64

EN ÇOK TEKRAR EDEN --- campaign --- DEĞERİ

1 17544

Name: campaign, dtype: int64



---pdays Value Counts ---

```

-1      36954
1         15
2         37
3          1
4          2

...

838        1
842        1

```


|     |   |
|-----|---|
| 850 | 1 |
| 854 | 1 |
| 871 | 1 |

Name: pdays, Length: 559, dtype: int64

EN ÇOK TEKRAR EDEN --- pdays --- DEĞERİ

-1 36954

Name: pdays, dtype: int64



---previous Value Counts ---

|    |       |
|----|-------|
| 0  | 36954 |
| 1  | 2772  |
| 2  | 2106  |
| 3  | 1142  |
| 4  | 714   |
| 5  | 459   |
| 6  | 277   |
| 7  | 205   |
| 8  | 129   |
| 9  | 92    |
| 10 | 67    |
| 11 | 65    |
| 12 | 44    |
| 13 | 38    |
| 14 | 19    |
| 15 | 20    |
| 16 | 13    |
| 17 | 15    |
| 18 | 6     |
| 19 | 11    |
| 20 | 8     |
| 21 | 4     |

```


22      6
23      8
24      5
25      4
26      2
27      5
28      2
29      4
30      3
32      1
35      1
37      2
38      2
40      1
41      1
51      1
55      1
58      1
275     1
Name: previous, dtype: int64

```

```

EN ÇOK TEKRAR EDEN --- previous --- DEĞERİ
0      36954
Name: previous, dtype: int64

```



**1.0.10 describe() fonksiyonu,** veri setindeki sayısal veya kategorik değişkenler için temel istatistikleri özetlemek amacıyla kullanılır.

```
[151]: df.describe()
```

[151]:

|       | age          | balance       | day          | duration     | campaign \   |
|-------|--------------|---------------|--------------|--------------|--------------|
| count | 45211.000000 | 45211.000000  | 45211.000000 | 45211.000000 | 45211.000000 |
| mean  | 40.936210    | 1362.272058   | 15.806419    | 258.163080   | 2.763841     |
| std   | 10.618762    | 3044.765829   | 8.322476     | 257.527812   | 3.098021     |
| min   | 18.000000    | -8019.000000  | 1.000000     | 0.000000     | 1.000000     |
| 25%   | 33.000000    | 72.000000     | 8.000000     | 103.000000   | 1.000000     |
| 50%   | 39.000000    | 448.000000    | 16.000000    | 180.000000   | 2.000000     |
| 75%   | 48.000000    | 1428.000000   | 21.000000    | 319.000000   | 3.000000     |
| max   | 95.000000    | 102127.000000 | 31.000000    | 4918.000000  | 63.000000    |

|       | pdays        | previous     |
|-------|--------------|--------------|
| count | 45211.000000 | 45211.000000 |
| mean  | 40.197828    | 0.580323     |
| std   | 100.128746   | 2.303441     |
| min   | -1.000000    | 0.000000     |
| 25%   | -1.000000    | 0.000000     |
| 50%   | -1.000000    | 0.000000     |
| 75%   | -1.000000    | 0.000000     |
| max   | 871.000000   | 275.000000   |

Veri setinde 45.211 gözlem var, ancak bazı değişkenlerde eksik veri olabilir.

Bazı değişkenlerde uç değerler var (örn. balance ve pdays sütunlarında büyük sapmalar var).

Veri dağılımını anlamak için ortalama (mean) ve medyanı (50%) kıyaslamak önemli.

### 1.0.11 Yorumlayalım:

Verinin setindeki sayısal sütunlara ilişkin temel istatistiksel özetleri yorumlayalım.

- count: Her bir sütundaki gözlem sayısını gösterir. Bütün sütunlarda 45211 gözlem var, yani eksik veri bulunmuyor.
- mean: Ortalama değer. Her sütunun ortalama değerini verir.
- std: Standart sapma. Verilerin ortalamadan ne kadar sapma gösterdiğini ifade eder.
- min ve max: Minimum ve maksimum değerler.
- Yüzdelikler (25%, 50%, 75%):
  - 25% (Q1): Verilerin %25'inin bu değerin altında olduğu eşik (1. çeyrek).
  - 50% (Q2, Medyan): Verilerin ortanca değeri.
  - 75% (Q3): Verilerin %75'inin bu değerin altında olduğu eşik (3. çeyrek)

### 1.0.12 Değişken Bazlı Analiz:

**1. age (Yaş)** - Ortalama yaş: 40.93 - Minimum yaş: 18, maksimum yaş: 95 - %50'lik dilimde (medyan) yaş 39, yani yaş dağılımı hafif sağa çarpık olabilir. - Standart sapma 10.61, yani yaşlar orta derecede dağılmış.

**2. balance (Banka Bakiyesi)** - Ortalama bakiye: 1362.27 - Minimum: -8019, maksimum: 102127 → Negatif bakiyeler var! - Medyan: 448, yani bakiyelerin çoğu ortalamadan düşük. - Standart sapma 3044.76, yani bakiyeler çok değişken.

**3. day (Son iletişim günü)** - Minimum: 1, maksimum: 31 - Bu değişken ay içindeki günleri temsil ediyor. - Dağılımı büyük ihtimalle dengeli.

**4. duration (Son görüşme süresi - saniye)** - Ortalama çağrı süresi: 258 saniye (~4.3 dakika) - Medyan: 180 saniye (~3 dakika) - Maksimum: 4918 saniye (~82 dakika) → Çok uzun görüşmeler var! - Standart sapma yüksek (257.52), yani çağrı süreleri arasında büyük farklar var.

**5. campaign (İletişim sayısı - mevcut kampanya)** - Ortalama kişi başına kampanya: 2.76 kez - Maksimum: 63 kez → Bazı kişilere aşırı fazla ulaşılmış! - Medyan: 2, yani çoğu kişiye 2 kez ulaşılmış.

**6. pdays (Önceki kampanyadan beri geçen gün sayısı)** - Ortalama: 40.19 gün - Minimum: -1 → Hiç önceki kampanya katılımı olmayanları ifade ediyor. - Maksimum: 871 gün (~2.4 yıl)

**7. previous (Önceki kampanyadaki iletişim sayısı)** - Ortalama: 0.58, medyan: 0 - Maksimum: 275 kez → Bazı müşterilere çok fazla ulaşılmış. - Çoğu müşteriye önceki kampanyalarda hiç ulaşılmamış (medyan 0).

### 1.0.13 Genel Sonuçlar ve Öneriler

- Yaş değişkeni dengeli, ancak 95 yaş gibi uç noktalar var.
- Banka bakiyesi değişkeni aşırı oynak, negatif ve çok yüksek değerler içeriyor.
- Çağrı süreleri çok değişken. Uzun çağrılar kampanyanın başarısını etkileyebilir.
- Bazı müşterilere çok fazla kampanya çağrısı yapılmış. Bu spam riski yaratabilir.
- pdays sütunundaki -1 değeri : Hiç önceki kampanya katılımı olmayanları ifade ediyor.

### 1.0.14 Veri Dağılımlarının Çarpıklık (Skewness) Analizi

Bir değişkenin sağa veya sola çarpık olup olmadığını anlamak için ortalama (mean) ve medyan (50%) kıyaslanır:

- Sağa Çarpık (Pozitif Skewness): Ortalama > Medyan
  - Uzun kuyruk sağa doğru uzar (büyük değerler daha fazla etkiler).
- Sola Çarpık (Negatif Skewness): Ortalama < Medyan
  - Uzun kuyruk sola doğru uzar (küçük değerler daha fazla etkiler).
- Simetrik Dağılım: Ortalama = Medyan
- **age (Yaş)**
  - 40.93(mean),
  - 39.0(median),
  - Sağa Çarpık, Yaşın büyük değerlerinde kuyruk var.
- **balance (Bakiye)**
  - 1362.27(mean),
  - 448.0(median),
  - Sağa Çarpık, Bazı müşterilerin çok yüksek bakiyesi var.
- **day (Son iletişim günü)**

- 15.86(mean),
- 16.0(median),
- Simetrik Günler eşit dağılmış görünüyor.
- **duration (Çağrı süresi)**
  - 258.16(mean),
  - 180.0(median),
  - Sağa Çarpık, Çok uzun görüşmeler var.
- **campaign (Mevcut kampanya iletişim sayısı)**
  - 2.76(mean),
  - 2.0(median),
  - Sağa Çarpık, Bazı müşterilere aşırı fazla çağrı yapılmış.
- **pdays (Önceki kampanyadan sonra geçen gün)**
  - 40.19(mean),
  - -1.0(median),
  - Sağa Çarpık, -1 değeri eksik veriyi temsil edebilir.
- **previous (Önceki kampanya iletişim sayısı)**
  - 0.58(mean),
  - 0.0(median),
  - Sağa Çarpık, Çoğu kişiye hiç çağrı yapılmamış, az sayıdaki kişi çok fazla çağrı almış.

**Numeric değişkenlerde eksik değer bulunması halinde mean veya medyana göre veriyi doldurma işlemi gerçekleştirilecektir.**

#### **Boş Değerlerde Ortalama Hesaplama Nasıl Gerçekleştirilmelidir?**

- Python’da mean() fonksiyonunda skipna=True parametresi ile eksik değerlerin hesaplamaya dahil edilip edilmeyeceği kontrol edilir. Python’da bunun karşılığı skipna parametresidir.
  - ÖRN: df[“num\_cols”].mean(skipna=True) # Eksik değerleri yok sayarak hesaplar (varsayılan True)
- Eğer eksik değerler varsa ve hata almak istiyorsak:
  - ÖRN: if df[“numeric\_column”].isnull().any():
    - \* raise ValueError(“Eksik değerler var, hesaplama yapılamaz!”)

#### **1.0.15 describe(include="object") fonksiyonu, veri setindeki kategorik değişkenlerin temel istatistiklerini özetlemek için kullanılır.**

```
[152]: df.describe(include="object")
```

```
[152]:
```

|        | job         | marital | education | default | housing | loan  | contact  | \ |
|--------|-------------|---------|-----------|---------|---------|-------|----------|---|
| count  | 45211       | 45211   | 45211     | 45211   | 45211   | 45211 | 45211    |   |
| unique | 12          | 3       | 4         | 2       | 2       | 2     | 3        |   |
| top    | blue-collar | married | secondary | no      | yes     | no    | cellular |   |
| freq   | 9732        | 27214   | 23202     | 44396   | 25130   | 37967 | 29285    |   |

|        | month | poutcome | y     |
|--------|-------|----------|-------|
| count  | 45211 | 45211    | 45211 |
| unique | 12    | 4        | 2     |
| top    | may   | unknown  | no    |
| freq   | 13766 | 36959    | 39922 |

### 1.0.16 Yorumlayalım:

- **Count:** Her değişkende kaç adet veri olduğu (Eksik değer yok gibi görünüyor).
- **Unique:** Her değişkende kaç farklı kategori olduğu.
- **Top:** En sık görülen kategori (mod).
- **Freq:** En sık görülen kategorinin kaç kez tekrar ettiği.
- Değişken : **job (Meslek)**
  - Kategori Sayısı (unique): 12
  - En Sık Görülen Değer (top): blue-collar (Mavi yakalı)
  - Frekans (freq): 9732
  - Yorum: Veri setinde en fazla mavi yakalı çalışanlar var.
- Değişken : **marital (Medeni Durum)**
  - Kategori Sayısı (unique): 3
  - En Sık Görülen Değer (top): married (Evli)
  - Frekans (freq): 27214
  - Yorum: Çoğu kişi evli.
- Değişken : **education (Eğitim Durumu)**
  - Kategori Sayısı (unique): 4
  - En Sık Görülen Değer (top): secondary (Orta öğretim)
  - Frekans (freq): 23202
  - Yorum: Çoğu kişi orta öğretim mezunu.
- Değişken : **default (Kredi Kartı Borcu)**
  - Kategori Sayısı (unique): 2
  - En Sık Görülen Değer (top): no
  - Frekans (freq): 25130
  - Yorum: Çoğu kişinin konut kredisi var.
- Değişken : **housing (Konut Kredisi)**
  - Kategori Sayısı (unique): 2
  - En Sık Görülen Değer (top): yes
  - Frekans (freq): 44396
  - Yorum: Çoğu kişinin kredi borcu yok.
- Değişken : **loan (Tüketici Kredisi)**
  - Kategori Sayısı (unique): 2
  - En Sık Görülen Değer (top): no
  - Frekans (freq): 37967
  - Yorum: Çoğu kişinin tüketici kredisi yok.
- Değişken : **contact (İletişim Türü)**
  - Kategori Sayısı (unique): 3
  - En Sık Görülen Değer (top): cellular (Cep telefonu)
  - Frekans (freq): 29285
  - Yorum: Çoğu kişi cep telefonuyla aranmış.



- Değişken : **month (Son İletişim Ayı)**
  - Kategori Sayısı (unique): 12
  - En Sık Görülen Değer (top): may (Mayıs)
  - Frekans (freq): 13766
  - Yorum: Kampanyaların çoğu Mayıs ayında yapılmış.
- Değişken : **poutcome (Önceki Kampanya Sonucu)**
  - Kategori Sayısı (unique): 4
  - En Sık Görülen Değer (top): unknown (Bilinmiyor)
  - Frekans (freq): 36959
  - Yorum: Çoğu kişi için önceki kampanya sonucu bilinmiyor.
- Değişken : **y (Hedef Değişken - Kampanya Sonucu)**
  - Kategori Sayısı (unique): 2
  - En Sık Görülen Değer (top): no
  - Frekans (freq): 39922
  - Yorum: Çoğu kişi kampanyaya katılmamış.

#### 1.0.17 2.2.Gerekli görsel analizlerin gerçekleştirilmesi (veriyi daha yakından tanımak amacıyla)

```
[153]: # Kampanyaya Katılım Oranları - Genel Çıkarım

import seaborn as sns
import matplotlib.pyplot as plt

# Grafik alanı oluşturma
fig, ax = plt.subplots(1, 2, figsize=(18, 8))

# Pasta grafiği (Pie chart)
df['y'].value_counts().plot.pie(
    explode=[0, 0.1],
    autopct='%1.1f%%',
    ax=ax[0],
    shadow=True,
    startangle=90,
    colors=['lightblue', 'salmon']
)
ax[0].set_title('Kampanyaya Katılım Dağılımları')
ax[0].set_ylabel('') # Y etiketini kaldırma

# Sütun grafiği (Countplot)
sns.countplot(x="y", data=df, ax=ax[1], palette=['lightblue', 'salmon'])
ax[1].set_title('Kampanyaya Katılım Dağılımları')


# Sütunların üzerine sayıları ekleme
for p in ax[1].patches:
    ax[1].annotate(
        f'{p.get_height()}', # Sayıyı almak
```

```

        (p.get_x() + p.get_width() / 2, p.get_height()), # Etiket'in yerini
    ↪ayarla
        ha='center', va='center', fontsize=10, color='black',
        xytext=(0, 8), textcoords='offset points' # Etiket'in çubuğun biraz
    ↪üstünde olması
    )

# Grafikleri gösterme
plt.tight_layout() # Düzenin düzgün olmasını sağla
plt.show()

```



Grafikten de görüldüğü gibi, veri setinde sınıf dengesizliği bulunuyor. - “No” sınıfı (kampanyaya katılmayanlar) %88.3 oranında, - “Yes” sınıfı (katılanlar) ise sadece %11.7 oranında yer alıyor.

Bu, model eğitimi sırasında sınıf dengesizliği sorunlarına yol açabilir.

Bu tür dengesiz veri setlerinde:

- Modelin çoğunluk sınıfına yönelme eğilimi olabilir.
- Eğitim/test verisini ayırırken dengeli bir dağılım sağlanmalı
- Cross-validation yaparken verinin sıralı olmamasına dikkat edilmeli, aksi takdirde model belirli dönemlere aşırı uyum sağlayabilir.

[154]: # Kategorik Değişkenlerin Dağılımı - piechart

```

import seaborn as sns
import matplotlib.pyplot as plt

# Kategorik sütunlar
categorical_columns = ['job', 'marital', 'education', 'default', 'housing',
    ↪'loan', 'contact', 'month', 'poutcome']

```

```


# Grafik alanı oluşturma
plt.figure(figsize=(18,15))

# For döngüsü ile her kategorik değişken için pasta grafiği oluşturma
for i, column in enumerate(categorical_columns, 1):
    plt.subplot(3, 3, i) # 2 satır, 3 sütunlu alt grafikleri yerleştir
    # Pasta grafiği (Pie chart)
    df[column].value_counts().plot.pie(
        autopct='%1.1f%%',
        ax=plt.gca(),
        startangle=180,
        colors=sns.color_palette("pastel"),
        explode=[0.03] * len(df[column].value_counts()) # Dilimleri biraz dışa
        ↪ çıkar
    )

    # Başlık
    plt.title(f"Distribution of {column.capitalize()}", fontsize=16)
    plt.ylabel('') # Y etiketini kaldırma

# Grafik düzeni
plt.tight_layout()
plt.show()

```



```
[155]: # Kategorik Değişkenlere Göre Kampanyaya Katılım Dağılımları

import matplotlib.pyplot as plt
import pandas as pd

# Tüm kategorik değişkenleri içeren liste (cat_cols)
categorical_columns = cat_cols

# Grafiklerin sayısını belirleyelim
fig, axes = plt.subplots(nrows=len(categorical_columns), figsize=(10, 5 *
    ↳len(categorical_columns)))

# Eğer tek değişken varsa axes liste olmaz, listeye çevirelim
if len(categorical_columns) == 1:
    axes = [axes]

# Her bir kategorik değişken için işlem yap
```

```

for col, ax in zip(categorical_columns, axes):
    # "yes" ve "no" dağılımını hesapla
    counts = df.groupby(col)["y"].value_counts().unstack().fillna(0)

    # Tabloyu yazdır
    print(f"\n{col} değişkenine göre Kampanyaya Katılım Dağılımı:\n")
    print(counts)

    # Bar plot çizdir
    counts.plot(kind="bar", stacked=True, ax=ax, color=["lightblue", "salmon"])

    # Başlık ve etiketler
    ax.set_title(f"{col} değişkenine göre Kampanyaya Katılım Dağılımı",
    ↪ fontsize=14)
    ax.set_xlabel(col, fontsize=12)
    ax.set_ylabel("Kişi Sayısı", fontsize=12)

    # Her bir barın üstüne sayısal değerleri ekle
    for container in ax.containers:
        ax.bar_label(container, fmt="%.0f", label_type="edge", fontsize=9,
        ↪ padding=4)

plt.tight_layout()
plt.show()

```

job değişkenine göre Kampanyaya Katılım Dağılımı:

| y             | no   | yes  |
|---------------|------|------|
| job           |      |      |
| admin.        | 4540 | 631  |
| blue-collar   | 9024 | 708  |
| entrepreneur  | 1364 | 123  |
| housemaid     | 1131 | 109  |
| management    | 8157 | 1301 |
| retired       | 1748 | 516  |
| self-employed | 1392 | 187  |
| services      | 3785 | 369  |
| student       | 669  | 269  |
| technician    | 6757 | 840  |
| unemployed    | 1101 | 202  |
| unknown       | 254  | 34   |

marital değişkenine göre Kampanyaya Katılım Dağılımı:

| y       | no | yes |
|---------|----|-----|
| marital |    |     |

|          |       |      |
|----------|-------|------|
| divorced | 4585  | 622  |
| married  | 24459 | 2755 |
| single   | 10878 | 1912 |

education değişkenine göre Kampanyaya Katılım Dağılımı:

| y         | no    | yes  |
|-----------|-------|------|
| education |       |      |
| primary   | 6260  | 591  |
| secondary | 20752 | 2450 |
| tertiary  | 11305 | 1996 |
| unknown   | 1605  | 252  |

default değişkenine göre Kampanyaya Katılım Dağılımı:

| y       | no    | yes  |
|---------|-------|------|
| default |       |      |
| no      | 39159 | 5237 |
| yes     | 763   | 52   |

housing değişkenine göre Kampanyaya Katılım Dağılımı:

| y       | no    | yes  |
|---------|-------|------|
| housing |       |      |
| no      | 16727 | 3354 |
| yes     | 23195 | 1935 |

loan değişkenine göre Kampanyaya Katılım Dağılımı:

| y    | no    | yes  |
|------|-------|------|
| loan |       |      |
| no   | 33162 | 4805 |
| yes  | 6760  | 484  |

contact değişkenine göre Kampanyaya Katılım Dağılımı:

| y         | no    | yes  |
|-----------|-------|------|
| contact   |       |      |
| cellular  | 24916 | 4369 |
| telephone | 2516  | 390  |
| unknown   | 12490 | 530  |

month değişkenine göre Kampanyaya Katılım Dağılımı:

| y     | no   | yes |
|-------|------|-----|
| month |      |     |
| apr   | 2355 | 577 |
| aug   | 5559 | 688 |










|     |       |     |
|-----|-------|-----|
| dec | 114   | 100 |
| feb | 2208  | 441 |
| jan | 1261  | 142 |
| jul | 6268  | 627 |
| jun | 4795  | 546 |
| mar | 229   | 248 |
| may | 12841 | 925 |
| nov | 3567  | 403 |
| oct | 415   | 323 |
| sep | 310   | 269 |

poutcome değişkenine göre Kampanyaya Katılım Dağılımı:

| y        | no    | yes  |
|----------|-------|------|
| poutcome |       |      |
| failure  | 4283  | 618  |
| other    | 1533  | 307  |
| success  | 533   | 978  |
| unknown  | 33573 | 3386 |

y değişkenine göre Kampanyaya Katılım Dağılımı:

| y   | no      | yes    |
|-----|---------|--------|
| y   |         |        |
| no  | 39922.0 | 0.0    |
| yes | 0.0     | 5289.0 |





```
[156]: # y'ye göre numeric değişkenlerin dağılımının yes ve no'ya göre ayrı ayrı
        ↪grafikleştirilmesi

import seaborn as sns
import matplotlib.pyplot as plt

# Sayısal sütunlar
num_cols = ['age', 'balance', 'day', 'duration', 'campaign', 'pdays',
            ↪'previous']

# Grafik alanı oluşturma
plt.figure(figsize=(18, 12))

# For döngüsü ile her bir sayısal sütun için histogram oluşturma
for i, column in enumerate(num_cols, 1):
    plt.subplot(3, 3, i) # 3 satır, 3 sütunlu alt grafikleri yerleştir

    # Veriyi 'yes' ve 'no'ya göre ayırma
    sns.histplot(data=df, x=column, hue='y', kde=True, bins=38,
    ↪palette="pastel", stat="density")

    # Başlık, etiketler ve çizgiler
    plt.title(f'Distribution of {column.capitalize()}', fontsize=16)
    plt.xlabel(column.capitalize(), fontsize=14)
    plt.ylabel('Density', fontsize=14)

    # 'yes' ve 'no'ya göre ortalama ve medyan hesaplama
    mean_yes = df[df['y'] == 'yes'][column].mean()
    median_yes = df[df['y'] == 'yes'][column].median()


    mean_no = df[df['y'] == 'no'][column].mean()
    median_no = df[df['y'] == 'no'][column].median()

    # 'yes' ve 'no' için ortalama ve medyan çizgilerini ekleme
    plt.axvline(mean_yes, color='blue', linestyle='--', label=f'Mean (Yes):
    ↪{mean_yes:.2f}')
    plt.axvline(median_yes, color='red', linestyle='-', label=f'Median (Yes):
    ↪{median_yes:.2f}')

    plt.axvline(mean_no, color='green', linestyle='--', label=f'Mean (No):
    ↪{mean_no:.2f}')
    plt.axvline(median_no, color='orange', linestyle='-', label=f'Median (No):
    ↪{median_no:.2f}')
```

```
# Grafikteki ortalama ve medyan çizgilerini gösterme
plt.legend()
```

```
# Grafik düzeni
plt.tight_layout()
plt.show()
```



Yorumlayalım:

- Age (Yaş Dağılımı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Ortalama, medyandan daha büyük.
  - Yorum: Histogramın sağ kuyruğu (yüksek yaş değerleri) sol kuyruğuna göre daha uzun.
- Balance (Bakiye Dağılımı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Ortalamalar medyandan büyük.
  - Yorum: Az sayıda kişi çok yüksek bakiyeye sahip.
- Day (Görüşme Günü Dağılımı)
  - Dağılım: Düzensiz, belirgin bir çarpıklık yok. bimodal (iki tepe noktalı) veya düzensiz bir dağılım göstermektedir.
  - Ortalama & Medyan: Yakın değerler.

- Yorum: Müşteri görüşmeleri her güne dağılmış.
- Duration (Görüşme Süresi Dağılımı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Ortalama medyandan büyük.
  - Yorum: Çoğu görüşme kısa, az sayıda uzun görüşme var.
- Campaign (Kampanya Temas Sayısı Dağılımı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Ortalama medyandan büyük.
  - Yorum: Çoğu müşteri az sayıda temas almış.
- Pdays (Önceki Kampanyaya Son Katılım Gün Sayısı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Ortalama yüksek, medyan -1 (çoğu hiç katılmamış).
  - Yorum: Çoğu müşteri önceki kampanyalara katılmamış.
- Previous (Önceki Kampanya İletişim Sayısı Dağılımı)
  - Dağılım: Sağa çarpık.
  - Ortalama & Medyan: Çoğu müşteri 0 veya 1 temas almış.
  - Yorum: Önceki kampanyalarla çok az kişiyle tekrar iletişim kurulmuş.

## Korelasyon Nedir?

Korelasyon, iki değişken arasındaki ilişkinin yönünü ve gücünü ölçen bir istatistiksel kavramdır. Korelasyon katsayısı (-1 ile +1 arasında) değişir: - Pozitif Korelasyon (+1'e yakın): Değişkenlerden biri artarken diğeri de artar. - Negatif Korelasyon (-1'e yakın): Biri artarken diğeri azalır. - Korelasyon 0'a yakın: İki değişken arasında güçlü bir ilişki yoktur.

**Korelasyon matrisi**, veri setindeki tüm sayısal değişkenlerin birbirleriyle olan korelasyonlarını gösteren bir tablodur. - Genellikle `corr()` fonksiyonu ile oluşturulur.

```
[157]: # Korelasyon matrisi yaparak değişkenlerin birbirine olan ilişkisini
      ↪ gözlemleyelim.
```


```
corr_matrix = df.corr(numeric_only=True)
```

```
[158]: corr_matrix
```

```
[158]:
```

|          | age       | balance   | day       | duration  | campaign  | pdays     | previous  |
|----------|-----------|-----------|-----------|-----------|-----------|-----------|-----------|
| age      | 1.000000  | 0.097783  | -0.009120 | -0.004648 | 0.004760  | -0.023758 | 0.001288  |
| balance  | 0.097783  | 1.000000  | 0.004503  | 0.021560  | -0.014578 | 0.003435  | 0.016674  |
| day      | -0.009120 | 0.004503  | 1.000000  | -0.030206 | 0.162490  | -0.093044 | -0.051710 |
| duration | -0.004648 | 0.021560  | -0.030206 | 1.000000  | -0.084570 | -0.001565 | 0.001203  |
| campaign | 0.004760  | -0.014578 | 0.162490  | -0.084570 | 1.000000  | -0.088628 | -0.032855 |
| pdays    | -0.023758 | 0.003435  | -0.093044 | -0.001565 | -0.088628 | 1.000000  | 0.454820  |
| previous | 0.001288  | 0.016674  | -0.051710 | 0.001203  | -0.032855 | 0.454820  | 1.000000  |

```
[159]: plt.figure(figsize=(8,6))
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm")
plt.show()
```



### 1.0.18 Korelasyon Matrisinin Yorumu

- Güçlü Pozitif Korelasyonlar:
  - pdays ve previous (0.45) → Önceki kampanya ile iletişim kurulan gün sayısı (pdays) ve geçmiş kampanyalara katılım sayısı (previous) arasında orta derecede pozitif bir ilişki var. Yani, bir müşterinin geçmişte kampanyalara katılımı arttıkça, yeniden iletişime geçildiği gün sayısı da artma eğiliminde.
- Zayıf Pozitif Korelasyonlar:
  - balance ve age (0.098) → Yaş arttıkça banka hesap bakiyesinin de artma eğiliminde olduğunu gösteriyor, ancak ilişki zayıf.
  - day ve duration (0.16) → Gün ile görüşme süresi arasında hafif bir pozitif korelasyon var. Yani belirli günlerde yapılan görüşmelerin süresi biraz daha uzun olabilir.
- Zayıf Negatif Korelasyonlar:

- campaign ve duration (-0.085) → Kampanya sayısı arttıkça görüşme süresinin azalma eğiliminde olduğunu gösteriyor. Yani, daha fazla kampanyaya katılan kişilerle yapılan görüşmeler daha kısa olabilir.
- pdays ve campaign (-0.089) → Kampanya sayısı arttıkça iletişime geçildiği gün sayısının azalması arasında hafif bir ilişki var.
- Korelasyonun Neredeyse Olmadığı Değişkenler:
  - age ile diğer değişkenler (~0.001 - 0.098) → Yaşın, diğer değişkenlerle neredeyse hiç ilişkisi yok.
  - balance ile diğer değişkenler (~0.003 - 0.098) → Banka bakiyesi ile diğer değişkenler arasında belirgin bir ilişki yok.

### Genel Çıkarım:

- Çoğu değişken arasındaki korelasyon çok zayıf. Yani veri setindeki değişkenler arasında doğrudan güçlü bir ilişki bulunmuyor.
- pdays ve previous arasında orta düzeyde bir pozitif ilişki var → Önceki kampanyalara katılım arttıkça, müşteriyle iletişime geçildiği gün sayısı da artıyor.
- Diğer korelasyonlar 0'a yakın, yani veri setinde güçlü ilişkiler pek bulunmuyor.

### 1.0.19 2.3.Cevaplanması gereken soruların belirlenmesi, yorumlanması ve gerekli olması durumunda görselleştirilmesi

[160]: *# Soru 1: Hedef kolonunda (yes\_no) oran nasıldır? Veri dengesiz mi?*

```
# Hedef kolonu ("yes_no") değerlerinin oranını hesaplayın
oranlar = df['y'].value_counts(normalize=True)
print(oranlar)
```

```
no      0.883015
yes     0.116985
Name: y, dtype: float64
```

### Soru 1 için Yorum:

Eğer bir kategori çok fazla, diğer kategori ise çok azsa, bu veri seti dengesiz demektir.

Denge durumu genellikle %70-%30 oranlarının üstünderse veri dengesiz kabul edilir.

Bizim verimiz “no” (kampanyaya katılmayanlar) oranı %88,3 ve “yes” (kampanyaya katılanlar) oranı %11,6.

Bu durumda evet veri setimiz dengesizdir.

### NOTE:

- Dengesiz dağılım olması sebebiyle ileriki adımlarda kurulan modeller karşılaştırılırken Accuracy değeri değil de F1-Score dikkate alınarak değerlendirmeler yapılacaktır.
- F1-Score, özellikle dengesiz veri setlerinde modelin azınlık sınıfına ne kadar duyarlı ve doğru olduğunu ölçerken daha anlamlı bir metrik sunar. Accuracy, dengesiz veri setlerinde yanıltıcı olabileceğinden, F1-Score genellikle daha doğru ve güvenilir bir değerlendirme sağlar.

(Görselleştirmesine yukarıda yer verilmiştir.)

```
[161]: # Soru 2: Kampanyaya katılım olarak "yes" kategorisindeki bireylerin ortalama
        ↳ "balance" değeri nedir?

ort_yes_balance = df[df["y"] == "yes"]["balance"].mean()

print(f"Kampanyaya katılım olarak yes kategorisindeki bireylerin ortalama
        ↳ 'balance' değeri: {ort_yes_balance}")
```

Kampanyaya katılım olarak yes kategorisindeki bireylerin ortalama 'balance' değeri: 1804.2679145396105

```
[162]: # Soru 3: housing durumu yes ve no olan konut kategorisindeki bireylerin
        ↳ "poutcome" değişkeninin dağılımı nasıldır?

house_yes = df[df["housing"] == "yes"]["poutcome"].value_counts()
house_no = df[df["housing"] == "no"]["poutcome"].value_counts()

print(f"housing durumu yes olan konut kategorisindeki bireylerin 'poutcome'
        ↳ değişkeninin dağılımı:\n{house_yes}")
print(f"housing durumu no olan konut kategorisindeki bireylerin 'poutcome'
        ↳ değişkeninin dağılımı:\n{house_no}")
```

housing durumu yes olan konut kategorisindeki bireylerin 'poutcome' değişkeninin dağılımı:

|         |       |
|---------|-------|
| unknown | 19990 |
| failure | 3470  |
| other   | 1199  |
| success | 471   |

Name: poutcome, dtype: int64

housing durumu no olan konut kategorisindeki bireylerin 'poutcome' değişkeninin dağılımı:

|         |       |
|---------|-------|
| unknown | 16969 |
| failure | 1431  |
| success | 1040  |
| other   | 641   |

Name: poutcome, dtype: int64

```
[163]: # Housing durumu "yes" olan bireylerin poutcome dağılımı
house_yes = {"success": 471, "failure": 3470, "other": 1199, "unknown": 19990}


# Housing durumu "no" olan bireylerin poutcome dağılımı
house_no = {"success": 1040, "failure": 1431, "other": 641, "unknown": 16969}

# Pie chart oluşturma
fig, axes = plt.subplots(1, 2, figsize=(12, 6))
```

```
# Housing: Yes
axes[0].pie(house_yes.values(), labels=house_yes.keys(), autopct='%1.1f%%',
            colors=['#ff9999', '#66b3ff', '#99ff99', '#ffcc99'])
axes[0].set_title("Poutcome Dağılımı (Housing: Yes)")

# Housing: No
axes[1].pie(house_no.values(), labels=house_no.keys(), autopct='%1.1f%%',
            colors=['#ff9999', '#66b3ff', '#99ff99', '#ffcc99'])
axes[1].set_title("Poutcome Dağılımı (Housing: No)")

plt.tight_layout()
plt.show()
```



[164]: # Soru 4: Aylara göre tercih edilen iletişim türü oranları nasıl değişmektedir?

```
contact_counts = df.groupby(["month", "contact"]).size().unstack()
print(contact_counts)
```

| contact | cellular | telephone | unknown |
|---------|----------|-----------|---------|
| month   |          |           |         |
| apr     | 2727     | 199       | 6       |
| aug     | 5950     | 246       | 51      |
| dec     | 174      | 37        | 3       |
| feb     | 2362     | 274       | 13      |
| jan     | 1265     | 129       | 9       |
| jul     | 5767     | 852       | 276     |
| jun     | 729      | 80        | 4532    |
| mar     | 417      | 53        | 7       |

|     |      |     |      |
|-----|------|-----|------|
| may | 5331 | 460 | 7975 |
| nov | 3540 | 379 | 51   |
| oct | 557  | 131 | 50   |
| sep | 466  | 66  | 47   |

```
[165]: import matplotlib.pyplot as plt
```

```
contact_ratios = contact_counts.div(contact_counts.sum(axis=1), axis=0) * 100
```

```
# Stacked bar chart oluşturma
```

```
contact_ratios.plot(kind='bar', stacked=True, figsize=(12,6),  
    color=['#ff9999', '#66b3ff', '#99ff99'])
```

```
plt.xlabel("Ay")
```


```
plt.ylabel("İletişim Türü Oranı (%)")
```

```
plt.title("Aylara Göre Tercih Edilen İletişim Türü Oranları")
```

```
plt.legend(title="İletişim Türü")
```

```
plt.xticks(rotation=45)
```

```
plt.show()
```



```
[166]: # Soru 5: İletişim türü göre kampanyaya katılım (yes-no) dağılım oranı nasıl  
    ↪ değişmektedir?
```

```
contact_yes_no = pd.crosstab(df["contact"], df["y"])
```



```
print(contact_yes_no)
```

| y         | no    | yes  |
|-----------|-------|------|
| contact   |       |      |
| cellular  | 24916 | 4369 |
| telephone | 2516  | 390  |
| unknown   | 12490 | 530  |

```
[167]: contact_ratios = contact_yes_no.div(contact_yes_no.sum(axis=1), axis=0) * 100
print(contact_ratios)
```

| y         | no        | yes       |
|-----------|-----------|-----------|
| contact   |           |           |
| cellular  | 85.081100 | 14.918900 |
| telephone | 86.579491 | 13.420509 |
| unknown   | 95.929339 | 4.070661  |

```
[168]: import matplotlib.pyplot as plt

# Yıgılmış çubuk grafiği oluşturma
contact_ratios.plot(kind="bar", stacked=True, figsize=(8, 6),
                    colormap="coolwarm")

plt.xlabel("İletişim Türü")
plt.ylabel("Oran (%)")
plt.title("İletişim Türüne Göre Yes/No Dağılımı")
plt.legend(title="Sonuç (y)")
plt.xticks(rotation=0)
plt.show()
```

