

6. Hafta Veri Temizleme ve Ön İşleme && 7. Hafta Özellik Seçimi ve Özellik Mühendisliği

April 1, 2025

1 6. Hafta - Veri Temizleme ve Ön İşleme

3.1. Eksik değerlerin tespiti ve giderilmesi, veri türlerinin düzenlenmesi

3.2. Kategorik değişkenlerin uygun şekilde düzenlenmesi ve kodlanması (gerekirse one-hot-encoding uygulayın.)

1.0.1 3.1. Eksik değerlerin tespiti ve giderilmesi, veri türlerinin düzenlenmesi

```
[132]: # Kullanacağımız kütüphaneleri yükleyelim.
```

```
# Pandas ve NumPy
import pandas as pd
import numpy as np
import seaborn as sns

# Görselleştirme kütüphaneleri
import matplotlib.pyplot as plt
import seaborn as sns
```

```
[133]: # Veri setini notebook içerisine dahil edelim.
```

```
# df = pd.read_csv("bank-additional-full.csv")

df = pd.read_csv("bank-full.csv", sep=";")
```

```
[134]: df.head(10)
```

```
[134]:   age      job  marital  education  default  balance  housing  loan  \
0   58  management   married   tertiary     no     2143     yes    no
1   44  technician   single   secondary     no       29     yes    no
2   33  entrepreneur   married   secondary     no        2     yes   yes
3   47  blue-collar   married    unknown     no    1506     yes    no
4   33     unknown   single    unknown     no        1      no    no
5   35  management   married   tertiary     no     231     yes    no
6   28  management   single   tertiary     no     447     yes   yes
7   42  entrepreneur  divorced   tertiary    yes        2     yes    no
```

8	58	retired	married	primary	no	121	yes	no
9	43	technician	single	secondary	no	593	yes	no

	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	unknown	5	may	261	1	-1	0	unknown	no
1	unknown	5	may	151	1	-1	0	unknown	no
2	unknown	5	may	76	1	-1	0	unknown	no
3	unknown	5	may	92	1	-1	0	unknown	no
4	unknown	5	may	198	1	-1	0	unknown	no
5	unknown	5	may	139	1	-1	0	unknown	no
6	unknown	5	may	217	1	-1	0	unknown	no
7	unknown	5	may	380	1	-1	0	unknown	no
8	unknown	5	may	50	1	-1	0	unknown	no
9	unknown	5	may	55	1	-1	0	unknown	no

```
[135]: df.columns
```

```
[135]: Index(['age', 'job', 'marital', 'education', 'default', 'balance', 'housing',
        'loan', 'contact', 'day', 'month', 'duration', 'campaign', 'pdays',
        'previous', 'poutcome', 'y'],
        dtype='object')
```

```
[136]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
#   Column      Non-Null Count  Dtype
---  -
0   age         45211 non-null  int64
1   job         45211 non-null  object
2   marital     45211 non-null  object
3   education   45211 non-null  object
4   default     45211 non-null  object
5   balance     45211 non-null  int64
6   housing     45211 non-null  object
7   loan        45211 non-null  object
8   contact     45211 non-null  object
9   day         45211 non-null  int64
10  month       45211 non-null  object
11  duration    45211 non-null  int64
12  campaign    45211 non-null  int64
13  pdays       45211 non-null  int64
14  previous    45211 non-null  int64
15  poutcome    45211 non-null  object
16  y           45211 non-null  object
dtypes: int64(7), object(10)
memory usage: 5.9+ MB
```

Yorumlayalım:

- 45211 toplam gözlem sayısı bulunuyor.
- Veri 17 feature içermektedir.
- 7 int64 tipinde, 10 object tipinde verimiz bulunmaktadır
- Veri içerisinde null değerler bulunmamaktadır.

1.0.2 Bank Marketing veri setinde eksik değerler hangi sütunlarda “unknown” değerleri olduğunu ve oranlarını inceleyelim.

Yorumlayalım:

Veri setimizde eksik değer bulunmamaktadır.

Bank Marketing veri setinin açıklamalarına göre, “unknown” değerleri eksik veri olarak kabul edilmemektedir. Veri setinin “Eksik Değerler Var mı?” (Has Missing Values?) kısmında “Hayır” (No) ifadesi yer almaktadır.

Bu durum, “unknown” olarak belirtilen değerlerin, eksik veri yerine, belirli özelliklerin (örneğin, müşterinin mesleği veya eğitim durumu) bilinmediğini veya kaydedilmediğini gösteren bir kategori olduğunu göstermektedir. Bu nedenle, “unknown” değerleri eksik veri olarak değil, mevcut verinin bir parçası olarak değerlendirilmelidir.

Peki burada unknown değerleri silmek mi?, doldurmak mı? yoksa ayrı bir kategori olarak değerlendirmek mi gerekir?

İlerideki adımlarda sütunlardaki unknown değerlerinin ayrı bir kategori olarak değerlendirilmesine karar verilmiştir.

SONUÇ:

unknown değeri içeren değişkenler için yorum:

- job (~ %0,5) (unknown oranları)
 - job = 288 unknown değeri bulunmaktadır.
 - Öneri: Bu sütunlarda “unknown” değerleri azınlıktadır. Bu nedenle, “unknown” değerlerini mevcut verilerle doldurabilir veya bu satırları analizden çıkarılabilir.
- contact (~ %28) (unknown oranları)
 - contact = 13020 unknown değeri bulunmaktadır.
 - Öneri: Bu sütunda “unknown” değerleri fazladır. Bu nedenle, “unknown” değerini ayrı bir kategori olarak tutmak veya bu sütunu analizden tamamen çıkarmak daha mantıklı olabilir.
- education (~ %4) (unknown oranları)
 - education = 1857 unknown değeri bulunmaktadır.
 - Öneri: Bu durumda, “unknown” değerlerini en yaygın kategoriyle doldurabilir veya bu satırları analizden çıkarabilirsiniz.
- Örnek: poutcome (~ %80)

- poutcome = 36959 unknown değeri bulunmaktadır.
- Öneri: Bu sütunda “unknown” değerleri baskındır. Bu nedenle, “unknown” değerini ayrı bir kategori olarak tutmak veya bu sütunu analizden tamamen çıkarmak daha mantıklı olabilir.

1.0.3 Sonuç olarak, her sütun için “unknown” değerlerinin oranını dikkate alarak uygun bir strateji belirlemelidir. Özellikle yüksek oranda “unknown” değeri içeren sütunlarda, bu değerleri ayrı bir kategori olarak tutmak veya sütunu analizden çıkarmak daha uygun olacaktır. Bu sebeple:

- **job, education, contact, poutcome** sütunundaki unknown değerlerini ayrı bir kategori olarak değerlendirilecektir. Veriden çıkarılmayacaktır.

```
[137]: # "unknown" değerlerini sayalım
unknown_counts = df.isin(["unknown"]).sum()
unknown_ratios = (df.isin(["unknown"]).sum() / len(df)) * 100

print(unknown_counts)
print("-----")
print(unknown_ratios)
```

```
age          0
job          288
marital      0
education    1857
default      0
balance      0
housing      0
loan         0
contact      13020
day          0
month        0
duration     0
campaign     0
pdays       0
previous     0
poutcome     36959
y            0
dtype: int64
-----
age          0.000000
job          0.637013
marital      0.000000
education    4.107407
default      0.000000
balance      0.000000
housing      0.000000
loan         0.000000
```

```
contact      28.798301
day           0.000000
month         0.000000
duration      0.000000
campaign      0.000000
pdays        0.000000
previous      0.000000
poutcome     81.747805
y             0.000000
dtype: float64
```

```
[138]: (df[["job","education","contact","poutcome"]] == "unknown").sum()
```

```
[138]: job          288
education  1857
contact    13020
poutcome   36959
dtype: int64
```

Eksik Değerleri Giderme Kararları - job, education sütunlarında “unknown” bulunan satırlar silindi.

- contact, poutcome sütunundaki “unknown” ayrı bir kategori olarak bırakıldı.

1.0.4 3.2. Kategorik değişkenlerin uygun şekilde düzenlenmesi ve kodlanması (gerekirse one-hot-encoding uygulayın.)

Veri Türlerinin Düzenlenmesi

Sayısal veri türleri:

- pdays: “-1” değeri, önceki kampanyada iletişim kurulmadığını gösteriyor. Bunu NaN ile değiştirebiliriz.

job, education’da bulunan “unknown” satırların silinmesiyle birlikte veri setimizdeki değerlerin toplam değer sayısı da azalmış olur.

```
[139]: # temizlenen veri setinde pdays sütunundaki -1 değerlerinin toplam sayısını
      ↪ getirelim

(df["pdays"] == -1).sum()
```

```
[139]: 36954
```

-1 olan değerleri NaN olarak güncelleyelim.

Hangi Durumda Hangisi Kullanılmalı?

Eğer sadece float değerler varsa → np.nan kullan (daha hızlıdır).

Eğer int, bool, string gibi türlerde eksik değer olarsa → pd.NA kullan.

Makine öğrenmesi ve istatistik işlemleri için → np.nan daha uyumludur.

Özetle: np.nan daha yaygın ve hızlıdır, pd.NA ise daha esnek ama daha yavaştır.

```
[140]: # pdays -1 olanları NaN olarak değiştirelim
df["pdays"] = df["pdays"].replace(-1, np.nan)
```

```
[141]: # toplam pdays gözlem sayısı - NaN değerler dahil

df["pdays"].count()
df.shape[0]
```

```
[141]: 45211
```

```
[142]: # pdays sütunundaki toplam NaN değer sayısı

df["pdays"].isna().sum()
```

```
[142]: 36954
```

Temizlenen veri setindeki pdays toplam sayısı = 43193

Temizlenen veri setindeki pdays eksik değer sayısı = 36954

- Eksik veri oranı %50'nin çok üzerinde olduğu için eksik değerleri doldurmak yerine sütunu kaldırmak genellikle daha iyi bir yaklaşım olacaktır.
- Eğer eksik değerleri doldurursan, doldurduğun değerlerin veriye gerçek bir katkısı olmayabilir ve modelin yanlış öğrenmesine sebep olabilir.
- Eksik değerleri doldurmak güvenilir olmaz → Ortalama veya medyan ile doldurursak, yapay bir veri üretmiş oluruz, bu da modelin yanlış öğrenmesine neden olabilir.

Bu sebeple pdays'deki NaN değerlerin sayısı çok yüksek olduğu için sütunu veriden kaldırmak daha sağlıklı olacaktır.

```
[143]: # pdays sütunun kaldırılması

df.drop(columns=["pdays"], inplace=True)
```

Kategorik Değişkenlerin Kodlanması

Makine öğrenmesi modelleri kategorik verileri doğrudan işleyemez, bu yüzden uygun bir şekilde kodlanmaları gerekir.

Label Encoding (İkili Değişkenler)

İçerisinde sadece “yes” ve “no” olan değişkenler 0 ve 1 olarak kodlanır:

default, housing, loan, y (hedef değişken)

```
[144]: df.head()
```

```
[144]:   age      job  marital  education  default  balance  housing  loan  \
0   58  management  married   tertiary      no    2143      yes    no
```

1	44	technician	single	secondary	no	29	yes	no
2	33	entrepreneur	married	secondary	no	2	yes	yes
3	47	blue-collar	married	unknown	no	1506	yes	no
4	33	unknown	single	unknown	no	1	no	no

	contact	day	month	duration	campaign	previous	poutcome	y
0	unknown	5	may	261	1	0	unknown	no
1	unknown	5	may	151	1	0	unknown	no
2	unknown	5	may	76	1	0	unknown	no
3	unknown	5	may	92	1	0	unknown	no
4	unknown	5	may	198	1	0	unknown	no

```
[145]: binary_cols = ["default", "housing", "loan", "y"]
df[binary_cols] = df[binary_cols].apply(lambda x: x.map({"yes": 1, "no": 0}))
```

One-Hot Encoding (Kategorik Değişkenler)

Kategorik değişkenleri dummies yöntemiyle encode edelim.

job, marital, education, contact, month, poutcome

```
[146]: df.dtypes
```

```
[146]: age          int64
job           object
marital       object
education     object
default       int64
balance       int64
housing       int64
loan          int64
contact       object
day           int64
month         object
duration      int64
campaign      int64
previous      int64
poutcome     object
y            int64
dtype: object
```

```
[147]: # Kategorik değişkenleri 'category' formatına çeviriyoruz. - Model kurarken
      ↪ problem çıkarmaması adına

categorical_cols = ["job", "marital", "education", "contact", "month",
      ↪ "poutcome"]
df[categorical_cols] = df[categorical_cols].astype("category")
```

```
[148]: df.dtypes
```

```
[148]: age                int64
      job                category
      marital            category
      education           category
      default            int64
      balance            int64
      housing            int64
      loan               int64
      contact            category
      day                int64
      month              category
      duration           int64
      campaign           int64
      previous           int64
      poutcome           category
      y                  int64
      dtype: object
```

Karşılaştırılacak olan modeller: - Lojistik Regresyon Modeli - K-Nearest Neighbors (KNN) Modeli
- Karar Ağaçları (Decision Tree) Modeli - Rastgele Orman (Random Forest) Modeli

Öneriler:

Karar ağaçları (Random Forest, XGBoost, LightGBM, CatBoost) genellikle category dtype destekler, yani doğrudan verebiliriz.

Logistic Regression veya Linear Regression gibi modellerde kategorik değişkenleri doğrudan verirken hata alırız. Çünkü bu algoritmalar yalnızca sayısal verilerle çalışır.

Scikit-Learn'in bazı modelleri (DecisionTreeClassifier vb.) Pandas category veri tipini desteklemez ve hata verebilir.

NOT: İleride karşılaştırılacak olan modellerde değişikliğe gidilebilir veya One-Hot-Encoding kullanarak model kullanıma uygun hale getirilebilir.

```
[ df_encoded = pd.get_dummies(df_cleaned, columns=["job", "marital", "education", "contact",  
"month", "poutcome"], drop_first=True) ]
```

```
[149]: df.columns
```

```
[149]: Index(['age', 'job', 'marital', 'education', 'default', 'balance', 'housing',  
        'loan', 'contact', 'day', 'month', 'duration', 'campaign', 'previous',  
        'poutcome', 'y'],  
        dtype='object')
```

2 7. Hafta: Özellik Seçimi ve Özellik Mühendisliği

4.1. Alan bilgisine dayalı olarak yeni özelliklerin üretilmesi (gerekliyse)

4.2. Gereksiz veya düşük etkili özelliklerin çıkarılması

4.3. Gerekli görsel analizlerin gerçekleştirilmesi

2.0.1 4.1. Alan bilgisine dayalı olarak yeni özelliklerin üretilmesi (gerekliyse)

Yeni özellikler türetirken müşteri davranışlarını, bankacılık işlemlerini ve pazarlama kampanyalarının etkisini anlamaya yönelik ek değişkenler oluşturacağız.

Yeni Özellik Önerileri

Müşterinin Finansal Durumu ile İlgili Özellikler:

balance_level (Bakiye Seviyesi):

Mevcut bakiyeye göre müşteriyi düşük, orta veya yüksek gelirli olarak sınıflandırır.

```
[150]: df["balance_level"] = pd.cut(df["balance"],
                                   bins=[-10000, 0, 2000, df["balance"].max()],
                                   labels=["düşük", "orta", "yüksek"])
```

```
[151]: df["balance_level"] = df["balance_level"].map({"düşük": 0, "orta": 1, "yüksek": 2})
```

```
[152]: df
```

```
[152]:
```

	age	job	marital	education	default	balance	housing	\
0	58	management	married	tertiary	0	2143	1	
1	44	technician	single	secondary	0	29	1	
2	33	entrepreneur	married	secondary	0	2	1	
3	47	blue-collar	married	unknown	0	1506	1	
4	33	unknown	single	unknown	0	1	0	
...	...	...	...	...	...	...	...	
45206	51	technician	married	tertiary	0	825	0	
45207	71	retired	divorced	primary	0	1729	0	
45208	72	retired	married	secondary	0	5715	0	
45209	57	blue-collar	married	secondary	0	668	0	
45210	37	entrepreneur	married	secondary	0	2971	0	

	loan	contact	day	month	duration	campaign	previous	outcome	y	\
0	0	unknown	5	may	261	1	0	unknown	0	
1	0	unknown	5	may	151	1	0	unknown	0	
2	1	unknown	5	may	76	1	0	unknown	0	
3	0	unknown	5	may	92	1	0	unknown	0	
4	0	unknown	5	may	198	1	0	unknown	0	
...	...	...	...	...	...	...	...	...	...	
45206	0	cellular	17	nov	977	3	0	unknown	1	
45207	0	cellular	17	nov	456	2	0	unknown	1	
45208	0	cellular	17	nov	1127	5	3	success	1	
45209	0	telephone	17	nov	508	4	0	unknown	0	
45210	0	cellular	17	nov	361	2	11	other	0	

	balance_level
0	2

```

1          1
2          1
3          1
4          1
...
45206      1
45207      1
45208      2
45209      1
45210      2

```

[45211 rows x 17 columns]

Müşterinin Kredileri ile İlgili Özellikler:

has_any_credit (Herhangi Bir Krediye Sahip Olup Olmama):

Müşterinin konut kredisi veya kişisel kredisi var mı?

```
[153]: df["has_any_credit"] = ((df["housing"] == 1) | (df["loan"] == 1)).astype(int)
```

Pazarlama Kampanyası Etkileşimi:

campaign_efficiency (Kampanya Etkinliği):

Bir müşteriye yapılan çağrı sayısının başarısıyla ilişkisini ölçer.

```
[154]: df["campaign_efficiency"] = df["previous"] / (df["campaign"] + 1)
```

```
[155]: df
```

```
[155]:
```

	age	job	marital	education	default	balance	housing	\
0	58	management	married	tertiary	0	2143	1	
1	44	technician	single	secondary	0	29	1	
2	33	entrepreneur	married	secondary	0	2	1	
3	47	blue-collar	married	unknown	0	1506	1	
4	33	unknown	single	unknown	0	1	0	
...	...	...	...	...	...	...	...	
45206	51	technician	married	tertiary	0	825	0	
45207	71	retired	divorced	primary	0	1729	0	
45208	72	retired	married	secondary	0	5715	0	
45209	57	blue-collar	married	secondary	0	668	0	
45210	37	entrepreneur	married	secondary	0	2971	0	

	loan	contact	day	month	duration	campaign	previous	poutcome	y	\
0	0	unknown	5	may	261	1	0	unknown	0	
1	0	unknown	5	may	151	1	0	unknown	0	
2	1	unknown	5	may	76	1	0	unknown	0	
3	0	unknown	5	may	92	1	0	unknown	0	
4	0	unknown	5	may	198	1	0	unknown	0	

```

...      ...      ...      ...      ...      ...      ...      ...
45206      0      cellular      17      nov      977      3      0      unknown      1
45207      0      cellular      17      nov      456      2      0      unknown      1
45208      0      cellular      17      nov      1127      5      3      success      1
45209      0      telephone      17      nov      508      4      0      unknown      0
45210      0      cellular      17      nov      361      2      11      other      0

```

```

      balance_level      has_any_credit      campaign_efficiency
0              2              1              0.000000
1              1              1              0.000000
2              1              1              0.000000
3              1              1              0.000000
4              1              0              0.000000
...
45206      1              0              0.000000
45207      1              0              0.000000
45208      2              0              0.500000
45209      1              0              0.000000
45210      2              0              3.666667

```

[45211 rows x 19 columns]

2.0.2 4.2. Gereksiz veya düşük etkili özelliklerin çıkarılması

Çıkarılması Gereken Özellikler:

duration (İletişim Süresi): Bu değişken, model için uygun değildir çünkü müşteriyle konuşma süresi, kampanya sonucunu belirlemede doğrudan kullanılamaz.

- duration: Modelleme aşamasında çıkarılabilir çünkü gelecekte tahmin edilemez.
- pdays sütunu veriden çıkarılmıştı.

```
[156]: # duration 'ın veriden çıkarılması
```

```
df.drop(columns=["duration"], axis=1, inplace=True)
```

```
[157]: # day veriden çıkarılması, modele doğrudan katkısı bulunmuyor
```

```
df.drop(columns=["day"], axis=1, inplace=True)
```

```
[158]: # balance sütununun silinmesi
```

```
df.drop(columns = ["balance"], axis=1, inplace=True)
```

```
[159]: df
```

```

[159]:      age      job      marital      education      default      housing      loan      \
0      58      management      married      tertiary      0      1      0
1      44      technician      single      secondary      0      1      0

```

2	33	entrepreneur	married	secondary	0	1	1
3	47	blue-collar	married	unknown	0	1	0
4	33	unknown	single	unknown	0	0	0
...	...	...	...	...	...	...	...
45206	51	technician	married	tertiary	0	0	0
45207	71	retired	divorced	primary	0	0	0
45208	72	retired	married	secondary	0	0	0
45209	57	blue-collar	married	secondary	0	0	0
45210	37	entrepreneur	married	secondary	0	0	0

	contact	month	campaign	previous	poutcome	y	balance_level	\
0	unknown	may	1	0	unknown	0		2
1	unknown	may	1	0	unknown	0		1
2	unknown	may	1	0	unknown	0		1
3	unknown	may	1	0	unknown	0		1
4	unknown	may	1	0	unknown	0		1
...	...	...	...	...	...	...		...
45206	cellular	nov	3	0	unknown	1		1
45207	cellular	nov	2	0	unknown	1		1
45208	cellular	nov	5	3	success	1		2
45209	telephone	nov	4	0	unknown	0		1
45210	cellular	nov	2	11	other	0		2

	has_any_credit	campaign_efficiency
0	1	0.000000
1	1	0.000000
2	1	0.000000
3	1	0.000000
4	0	0.000000
...	...	...
45206	0	0.000000
45207	0	0.000000
45208	0	0.500000
45209	0	0.000000
45210	0	3.666667

[45211 rows x 16 columns]

```
[160]: df.columns
```

```
[160]: Index(['age', 'job', 'marital', 'education', 'default', 'housing', 'loan',
        'contact', 'month', 'campaign', 'previous', 'poutcome', 'y',
        'balance_level', 'has_any_credit', 'campaign_efficiency'],
        dtype='object')
```

```
[161]: # Hiç eksik değer var mı yok mu kontrol et
```

```
df.isnull().any()
```

```
[161]: age                False
      job                False
      marital            False
      education           False
      default            False
      housing            False
      loan               False
      contact            False
      month              False
      campaign           False
      previous           False
      poutcome           False
      y                 False
      balance_level      False
      has_any_credit     False
      campaign_efficiency False
      dtype: bool
```


Yüksek Korelasyonlu Özellikler:

Eğer iki değişken yüksek korelasyona sahipse (örneğin %90+), bunlardan biri çıkarılabilir. Korelasyon matrisini inceleyerek bu karar verilebilir.

```
[162]: import seaborn as sns
      import matplotlib.pyplot as plt

      corr_matrix = df.corr()
      plt.figure(figsize=(15,10))
      sns.heatmap(corr_matrix, annot=True, cmap="coolwarm", fmt=".2f")
      plt.show()
```

```
C:\Users\Admin\AppData\Local\Temp\ipykernel_14304\2719940553.py:4:
FutureWarning: The default value of numeric_only in DataFrame.corr is
deprecated. In a future version, it will default to False. Select only valid
columns or specify the value of numeric_only to silence this warning.
      corr_matrix = df.corr()
```




```
[163]: # 0.9'dan yüksek korelasyonlu deęiřkenleri bulalım
high_corr = corr_matrix[abs(corr_matrix) > 0.9]

# Yüksek korelasyonlu deęiřkenlerden birini kaldırma kararı al (manuel analiz,
↳ gerekli)
df.drop(columns=["campaign_efficiency"], inplace=True) # Örnek olarak çıkarıldı
```

```
[164]: # Korelasyon matrisini çizelim
corr_matrix = df.corr()
plt.figure(figsize=(15,10))
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm", fmt=".2f")
plt.show()
```

C:\Users\Admin\AppData\Local\Temp\ipykernel_14304\1083992204.py:2:
FutureWarning: The default value of numeric_only in DataFrame.corr is deprecated. In a future version, it will default to False. Select only valid columns or specify the value of numeric_only to silence this warning.
corr_matrix = df.corr()



2.0.3 4.3. Gerekli görsel analizlerin gerçekleştirilmesi

1. Yeni Üretilen Özelliklerin Dağılımı


Yeni üretilen değişkenlerin veriyi nasıl etkilediğini görmek için dağılım grafikleri çizelim.

```
[165]: import seaborn as sns
import matplotlib.pyplot as plt

new_features = ["balance_level", "has_any_credit"]

plt.figure(figsize=(8,4))
for i, col in enumerate(new_features, 1):
    plt.subplot(1, 3, i)
    sns.histplot(df[col], kde=True)
    plt.title(f"{col} Dağılımı")

plt.tight_layout()
plt.show()
```



- balance_level Dağılımı:
 - Histogramdaki yüksek tepe noktası, belirli bir değerde (örneğin 1 civarında) aşırı birikim olduğunu gösteriyor.
 - Normal dağılımdan uzak, belirli bir noktada aşırı yığılmış ve dengesiz bir dağılım gösteriyor.
- has_any_credit Dağılımı:
 - Histogramda iki ana grup var: 0 ve 1 değerleri, yani çoğu veri noktası ya “kredisi yok” ya da “kredisi var” şeklinde ayrılmış.
 - KDE eğrisinin uç noktalarda keskin yükselmesi, veri noktalarının büyük kısmının bu iki değerde toplandığını gösteriyor.
 - Aykırı değer (outlier) veya ara değerler (örneğin 0.5 gibi) bulunmuyor, tamamen kategorik bir değişken gibi davranıyor.


2. Kampanya Başarısı ile Özelliklerin İlişkisi

Müşterinin kampanyaya katılım durumuna (y) göre yeni özelliklerin etkisini görselleştirelim.

```
[166]: plt.figure(figsize=(15,6))
for i, col in enumerate(new_features, 1):
    plt.subplot(2, 3, i)
    sns.boxplot(x=df["y"], y=df[col])
```

```
plt.title(f"Kampanya Sonucu ile {col} İlişkisi")

plt.tight_layout()
plt.show()
```



3. Özelliklerin Kampanya Başarısına Etkisi (Bar Grafikleri)

```
[167]: plt.figure(figsize=(15, 5))


for i, col in enumerate(["balance_level", "has_any_credit"], 1):
    plt.subplot(1, 3, i)

    # Sayıları hesapla
    count_data = df.groupby([col, "y"]).size().unstack()

    # Çubuk grafiği çiz
    sns.countplot(x=df[col], hue=df["y"])
    plt.title(f"{col} Göre Kampanya Katılımı")
    plt.legend(["Katılmadı", "Katıldı"])

    # Değerleri çubukların altına yazdır
    for index, value in enumerate(count_data.values):
        plt.text(index - 0.2, value[0] + 50, str(value[0]), color="black",
↪fontsize=10) # Katılmayanlar
        plt.text(index + 0.15, value[1] + 50, str(value[1]), color="black",
↪fontsize=10) # Katılanlar

plt.tight_layout()
plt.show()
```



```
[168]: df
```

```
[168]:
```

	age	job	marital	education	default	housing	loan	\
0	58	management	married	tertiary	0	1	0	
1	44	technician	single	secondary	0	1	0	
2	33	entrepreneur	married	secondary	0	1	1	
3	47	blue-collar	married	unknown	0	1	0	
4	33	unknown	single	unknown	0	0	0	
...	...	...	...	...	...	...	...	
45206	51	technician	married	tertiary	0	0	0	
45207	71	retired	divorced	primary	0	0	0	
45208	72	retired	married	secondary	0	0	0	
45209	57	blue-collar	married	secondary	0	0	0	
45210	37	entrepreneur	married	secondary	0	0	0	

	contact	month	campaign	previous	poutcome	y	balance_level	\
0	unknown	may	1	0	unknown	0	2	
1	unknown	may	1	0	unknown	0	1	
2	unknown	may	1	0	unknown	0	1	
3	unknown	may	1	0	unknown	0	1	
4	unknown	may	1	0	unknown	0	1	
...	...	...	...	...	...	...	...	
45206	cellular	nov	3	0	unknown	1	1	
45207	cellular	nov	2	0	unknown	1	1	
45208	cellular	nov	5	3	success	1	2	
45209	telephone	nov	4	0	unknown	0	1	
45210	cellular	nov	2	11	other	0	2	

	has_any_credit
0	1
1	1
2	1
3	1
4	0
...	...
45206	0
45207	0
45208	0
45209	0
45210	0

[45211 rows x 15 columns]

```
[169]: df.columns
```

```
[169]: Index(['age', 'job', 'marital', 'education', 'default', 'housing', 'loan',
        'contact', 'month', 'campaign', 'previous', 'poutcome', 'y',
        'balance_level', 'has_any_credit'],
        dtype='object')
```