

## Yapay Zeka Çağına Hazır Mısınız?

Dünya'nın en değerli kaynağı artık petrol değil veridir!!

The Economist

Yapay zeka yeni elektriktir!!!

Andrew NG

Yapay Zeka nedir?

Yapay zeka bir bilgisayarın veya bilgisayar kontrolündeki bir robotun çeşitli faaliyetleri zeki insanlara benzer şekilde yerine getirme kabiliyetidir.

Günlük hayattan yapay zeka uygulamaları örnekleri

- Arkadaş önerileri
- Otomatik fotoğraf etikelemeleri
- Hedefli içerik pazarlama
- Otomatik mesaj tamamlama
- Hedefli ürün pazarlama
- Tavsiye sistemleri

## Farklı Alanlardan Örnek Uygulamalar

- Müşteri segmentasyonu
- Kanser/ Hastalık teşhisi
- Şirketlerin gelir tahmini ile strateji belirlemesi
- Başvuru değerlendirme sistemleri(ör kredi başvurusu)  
Not:Sistem bu bilgileri veri tabanında geçmiş kişilerin verilerine bakarak ödeyip ödeyemeyeceğini tartıyor.
- Akıllı portföy yönetimi(borsadaki hisse senedi değerlerinin yönleri ve değerlerini tahmin ederek buna göre yatırım stratejileri uyguluyor)
- Doğal afet modelleme çalışmaları
- E-Spor analitiği

## Görüntü İşleme Temelli Uygulamalar

- Otonom araçlar
- Nesne tanıma/ takip uygulamaları  
Örn: dizi- person of interest -- günümüz örneği: Çin'deki kameralarla insanların sürekli takip edilmesi
- Sahte videolar (yapay zekanın post-truth çağına etkisine örnek olarak verilebilir)
- Eski resimlerin canlandırılması  
(<https://thispersondoesnotexist.com/>)
- Algoritmaların geliştirdiği resimler/ var olmayan kişiler
- Robotlar(örn: Boston Dynamics)

Bu uygulamaları geliřtiren kiřilere **Veri Bilimci** denir. Bütüncül olarak ele alan konu **Veri Bilimi** konusudur. Bu örneklerin ürünleřmesi için teorik alt yapıyı saęlayan algoritmalara **Makine Öğrenmesi** algoritmaları denir. Bu örnek uygulamaların ürünleřip bu řekilde hayatımıza girdięi son noktadaki haline ise **Yapay Zeka** denir.

## Yapay Zeka Çaęında Hayatta Kalmak

- Programlama
- Matematik
- İstatistik
- Veri Analizi
- Veri Bilimi
- Büyük Veri
- Yapay Zeka
- Derin Öğrenme
- Makine Öğrenmesi
- Nesnelerin İnterneti
- Endüstri 4.0
- Veri Madencilięi

Nasıl hayatta kalınır? - **Veri analitięi ve Analitik Düşünce Becerileri** ile elde edilir.

**Veri analitięi** bütüncül anlamda bir deęer üretmektir. Veri bilimi ile birlikte düşüneneęimiz bir kavramdır.

**Analitik düşünce** veri bilimi ve veri analitięi kapsamında üretilecek olan deęerdeki kiřisel potansiyellerimizdir.

Bu alandaki yetenekler řöyledir:

- Yeni sorular sormak
- Arařtırma
- Problem çözme
- Kavramların mantıklarına odaklanmak

Örn: İş görüşmesi yapacaęın kiřinin ilgi alanlarını önceden stalklamak ve bilgi sahibi olmak, beęendięi sayfaları, gönderileri incelemek. Böylece elimizde birkaç basit yorum olurdu.

## Sizi Sizden Daha İyi Taniyan Algoritmalar

**Algoritma:** Belirli bir amacı yerine getirmek için geręekleřtirilen işlemler dizisidir.


Örn: **ABD seçimlerinde** veri biliminin rolünün anlatıldıęı bu bölümde, veri bilimin dünyayı deęiřtirme gücü açıklanıyor. **Cambridge Analytica** řirketi **Analitik Beceriler ve Veri Analitięi** kullanarak 17 eyalet ve 32 kiřilik grubu (persona) kullanarak kiřiselleřtirilmiř seçim kampanyaları oluřturarak Amerika Bařkanının seęilmesinde analitik düşünce becerilerinin rolünü ortaya koyuyorlar.

## Veri Bilimi ve Veriden Faydalı Bilgi Çıkarmak

### Veri Bilimi ve Veri Bilimci

Veri Bilimi Nedir?

Veriden faydalı bilgi çıkarma sürecidir.



Elimizde bazı veri kaynakları var. Bu veri kaynakları üzerinde analitik düşünce becerileri ve veri analitiğini kullanarak bazı bilgiler çıkarılacak. Çıkarılan bu bilgileri aksiyona çevirdiğimiz sürece Veri Bilimi denir.


Veri Bilimci Nedir?

Veriden faydalı bilgi çıkarma sürecini yöneten kişidir.

### Veri Bilimci Yetenekleri



## Veriden Faydalı Bilgi Çıkarmak




4 tane Analitik türümüz var. Bu analitik türlerini kullanarak veriden anlamlı bilgi çıkarıyoruz. Zorluk arttıkça kullanılacak olduğumuz analitik türünün de katma değerinin arttığı gözlemleniyor.

- **Betimleyici Analitik** → Ne olmuş? Sorusuna yanıt aranır. (ort., std sapma, mod, medyan, görselleştirme teknikleri ile basit raporlar oluşturduğumuzda ve mevcut durumun resmini çektiğimizde aslında ne olmuş sorusuna yanıt ararız.

### Betimleyici Analitik

|        | OCAK | ŞUBAT | MART | NİSAN | MAYIS | HAZİRAN | TEMMUZ | AĞUSTOS | EYLÜL | EKİM | KASIM | ARALIK |
|--------|------|-------|------|-------|-------|---------|--------|---------|-------|------|-------|--------|
| 1. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | 220   | 340  | 370   | 290    |
| 2. Yıl | 12   | 22    | 34   | 210   | 220   | 270     | 210    | 320     | 250   | 280  | 390   | 316    |
| 3. Yıl | 11   | 21    | 32   | 205   | 225   | 280     | 205    | 315     | 235   | 310  | 380   | 303    |



- **Teşhis/ Tanı Analitiği** → Neden olmuş?/ Nasıl olmuş? Sorusuna yanıt arar.

### Teşhis / Tanı Analitiği

|        | OCAK | ŞUBAT | MART | NİSAN | MAYIS | HAZİRAN | TEMMUZ | AĞUSTOS | EYLÜL | EKİM | KASIM | ARALIK |
|--------|------|-------|------|-------|-------|---------|--------|---------|-------|------|-------|--------|
| 1. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | 220   | 340  | 370   | 290    |
| 2. Yıl | 12   | 22    | 34   | 210   | 220   | 270     | 210    | 320     | 250   | 280  | 390   | 316    |
| 3. Yıl | 11   | 21    | 32   | 205   | 225   | 280     | 205    | 315     | 235   | 310  | 380   | 303    |



Her yılın Ocak, Şubat, Mart aylarında satışlarda bir düşüklük olduğunu gözlemleyelim. Bu NEDEN OLMUŞ? Neden böyle bir durum oluşmuş? sorusunu sorarsak nedenlerinde belki üretim süreçlerinde bir sorun var. Veya bu aylarda elemanlarla ilgili bir problem var. Bunu tespit etmek gerekiyor.

- **Tahminsel Analitik** → Ne olacak? Sorusuna yanıt aranır. Nihai sonucu bilinmeyen olaylar ile ilgili tahminler yada gelecek ile ilgili tahminler yapmak için kullanılır.

### Tahminsel Analitik

Önümüzdeki 3 ay satışlar ne olacak? Ağustos ayındayız. Eylül, Ekim, Kasım aylarına ilişkin satışlarımızın ne olacağını tahmin etmek istiyoruz. İstatistiksel modellemeler, ekonometrik modellemeler ve makine öğrenmesi modellemeleri kullanılır.

|        | OCAK | ŞUBAT | MART | NİSAN | MAYIS | HAZİRAN | TEMMUZ | AĞUSTOS | EYLÜL | EKİM | KASIM | ARALIK |
|--------|------|-------|------|-------|-------|---------|--------|---------|-------|------|-------|--------|
| 1. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | 220   | 340  | 370   | 290    |
| 2. Yıl | 12   | 22    | 34   | 210   | 220   | 270     | 210    | 320     | 250   | 280  | 390   | 316    |
| 3. Yıl | 11   | 21    | 32   | 205   | 225   | 280     | 205    | 315     | 235   | 310  | 380   | 303    |
| 4. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | ?     | ?    | ?     |        |

- **Yönergeli(Normatif) Analitik** → Ne, nasıl olmalı? Sorusuna yanıt aranır.

### Yönergeli Analitik

|        | OCAK | ŞUBAT | MART | NİSAN | MAYIS | HAZİRAN | TEMMUZ | AĞUSTOS | EYLÜL | EKİM | KASIM | ARALIK |
|--------|------|-------|------|-------|-------|---------|--------|---------|-------|------|-------|--------|
| 1. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | 220   | 340  | 370   | 290    |
| 2. Yıl | 12   | 22    | 34   | 210   | 220   | 270     | 210    | 320     | 250   | 280  | 390   | 316    |
| 3. Yıl | 11   | 21    | 32   | 205   | 225   | 280     | 205    | 315     | 235   | 310  | 380   | 303    |
| 4. Yıl | 10   | 20    | 30   | 200   | 230   | 290     | 200    | 310     | 240   | 300  | 365   |        |

Ne yaparsam  
gelirlerim  
artar?

Tahminsel analitik ile satışları tahmin ettik. Gelirleri tahmin ettik ama ben bu gelirleri arttırmak için ne yapmalıyım? Eğitecek old. makine öğrenmesi algoritmalarına ben ne yaparsam satışlarım artar sorusunu yöneltilir bize vermiş olduğu yönergeler göre bazı iş aksiyon kararları alarak gelirleri bu doğrultuda arttırmaya çalışıyoruz.


Veriden faydalı bilgi çıkarınca ortaya çıkan örnekleri

## Veriden Faydalı Bilgi Çıkarmak

- Arkadaş önerileri
- Otomatik fotoğraf etiketlemeleri
- Hedefli içerik pazarlama
- Otomatik mesaj tamamlama
- Hedefli ürün pazarlama
- Tavsiye sistemleri
- Müşteri segmentasyonu
- Kanser/Hastalık teşhisi
- Şirketlerin gelir tahmini ile strateji belirlemesi
- Başvuru değerlendirme sistemleri
- Akıllı portföy yönetimi
- Doğal afet modelleme çalışmaları
- E-Spor Analitiği
- Otonom araçlar
- Nesne tanıma/takip uygulamaları
- Sahte videolar
- Eski resimlerin canlandırılması
- Algoritmaların geliştirdiği resimler/var olmayan kişiler
- Robotlar!

### CRISP-DM


Veri bilimi proje sürecini yönetmek için kullanılan CRISP-DM metodolojisi bir örnek üzerinden ele alınıyor.



## CRISP-DM Giriş

İş akışı süreçlerinin modellenmesidir. Sıfırdan bir ürün geliştirme işlemini genelde şirketler bu döngüyü takip ederek gerçekleştirir.

### İş Anlayışı – İş Problemi (Business Understanding)



Örneğin: İkinci el bir araç ilanı vererek bu aracı satmak istiyoruz. Değerinin ne kadar ettiğini bulmak istiyoruz diyelim.

Araç fiyat tahmin modeli kurmak istiyoruz.

Aracın km bilgisi, vites bilgisi, kaza durumu vs. belirtildiğinde bana ilgili arabanın benzer marka ve model bilgisi göz önünde bulundurularak kaç para edebileceği bilgisi verilsin.

Veri bilimci burada Veri Tabanlarından daha önceki verilere bakacak ve bir makine öğrenmesi modeli oluşturacak.

$$y = x_1 * b_1 + x_2 * b_2 + ..... + x_p * b_p$$

gibi bir model düşüneceğiz. Araca ilişkin bazı değerler fonksiyona yazılacak ve aracın fiyatının tahmini yapılacaktır.

## Veriyi Anlamak (Data Understanding)


Veriler, Veri Tabanlarında tutulur. Veri aslında basit bir excel tablosu gibi görünebilir.

Veri kaynaklarından veriyi aldığımızda bu veriyi anlamamız, incelememiz gerekiyor.

Bu şu şekilde sorularla mümkündür?

- Bu değişkenlerin ortalaması, standart sapması nedir? (özet istatistikler vs.)
- Marka, Model dağılımında A markasına ait A1 modellerin fiyat ortalaması nedir?
- A markasının Manuel viteslerinin fiyat değerleri nedir?, otomatik viteslerinin fiyatları nedir?
- Markaların ortalama fiyatları nedir?
- Hangi markadan kaç adet vardır?
- Aynı marka modellerde otomatik viteslerin fiyatları nelerdir?

# Veri



## Araç fiyat tahmin modeli hikayesi



| Araç Fiyatı | KM      | Vites Türü | Hasar Durumu | Marka | Model |
|-------------|---------|------------|--------------|-------|-------|
| 10000       | 300000  | Manuel     | Evet         | A     | A1    |
| 54000       | 40000   | Manuel     | Hayır        | A     | A2    |
| 46999       | 90000   | Manuel     | Evet         | B     | B1    |
| 89000       | 1000000 | Otomatik   | Evet         | C     | C1    |
| 70000       | 78000   | Otomatik   | Evet         | B     | B2    |
| 50000       | 30000   | Manuel     | Hayır        | C     | C2    |
| NA          | 600000  | Manuel     | Hayır        | C     | C3    |
| 68900       | 50000   | Otomatik   | Hayır        | B     | B2    |
| 12000       | 200000  | Manuel     | Hayır        | A     | A1    |

Biz bir galerici gibi fiyatın ne olabileceğini bilemeyiz ama veri tabanlarımızdaki verileri algoritmalarla öğretilip onları eğiterek uzmanlaştırabiliriz.

## Verinin Hazırlanması (Data Preparation)

Modelleme çalışmalarına geçmeden önce veri setini hazırlamamız gerekiyor. Veri setindeki yapısal bozuklukları ve bazı problemleri gidermemiz gerekiyor.

| Araç Fiyatı | KM      | Vites Türü | Hasar Durumu | Marka | Model |
|-------------|---------|------------|--------------|-------|-------|
| 10000       | 300000  | Manuel     | Evet         | A     | A1    |
| 54000       | 40000   | Manuel     | Hayır        | A     | A2    |
| 46999       | 90000   | Manuel     | Evet         | B     | B1    |
| 89000       | 1000000 | Otomatik   | Evet         | C     | C1    |
| 70000       | 78000   | Otomatik   | Evet         | B     | B2    |
| 50000       | 30000   | Manuel     | Hayır        | C     | C2    |
| NA          | 600000  | Manuel     | Hayır        | C     | C3    |
| 68900       | 50000   | Otomatik   | Hayır        | B     | B2    |
| 12000       | 200000  | Manuel     | Hayır        | A     | A1    |

Burada sarı ile işaretli yerler bozuklukları ifade etmektedir.

NA → eksik değer anlamına gelmektedir. Kaybolmuş değer/missing value. Tablo girişi ile ilgili hata veya veri girişi ile ilgili hata olabilir, kullanıcı değeri girmemiş olabilir siteye ilan verirken.

Buradaki bir ve birden fazla sıfırdan oluşan ifadede aykırı değerdir. Bir aracın km değerinin aslında böyle bir değerin olmamasıdır. Marka ve modele bakılınca o kadar da etmeyecek bir aracın olmasıdır.

**Aykırı değer** → Verinin yapısının oldukça dışında kalan değerlere aykırı değerler denir.

A marka aracın A2 modelinin Manuel modeli aslında yoktur. Ama tabloda manuel yazıyor. Bu da Gürültü diye ifade edilir. Bozuk bir değerdir.

Bu sebeple modellemeye geçmeden önce ortaya çıkan bozuklukları gidermek gerekir.



Not:  
Örnekte yer alan bozukluklar  
çeşitli teknikler ile giderilmektedir.  
Bu teknikler veri ön işleme  
kapsamında ele alınacaktır.

| Araç Fiyatı | KM     | Vites Türü | Hasar Durumu | Marka | Model |
|-------------|--------|------------|--------------|-------|-------|
| 10000       | 300000 | Manuel     | Evet         | A     | A1    |
| 54000       | 40000  | Otomatik   | Hayır        | A     | A2    |
| 46999       | 90000  | Manuel     | Evet         | B     | B1    |
| 89000       | 80000  | Otomatik   | Evet         | C     | C1    |
| 70000       | 78000  | Otomatik   | Evet         | B     | B2    |
| 50000       | 30000  | Manuel     | Hayır        | C     | C2    |
| 6000        | 600000 | Manuel     | Hayır        | C     | C3    |
| 68900       | 50000  | Otomatik   | Hayır        | B     | B2    |
| 12000       | 200000 | Manuel     | Hayır        | A     | A1    |

Bozuklukları giderilmiş bir  
veri görelim.

## Modelleme (Modeling)

Veri içerisinde yer alan yapıların algortimalara, fonksiyonlara öğretilmesi demektir.

Veri setinin içerisindeki bu yapıyı birçok algoritma ile öğrenip modelleyebiliriz. Bu modelleme tekniklerinden birisi ÇOKLU DOĞRULAMA REGRESYON MODELİ'dir.

Modellemek: Fiyat söz konusu olduğunda, fiyatı etkilediğini bildiğimiz km, vites durumu, hasar durumu vb. değişkenlerin etkilerinin yönünü ve şiddetini bulmak demektir.

Örn: bir arabanın otomatik vites olması veya benzinli olması fiyata etki eder.

Kazalı olması negatif etki eder, km'nin yüksek olması negatif etki eder, hasarlı olması negatif etki eder. Fiyatı düşürür.

Ama biz örn A marka B model aracın km'si arttığında fiyata nasıl bir etkisi olduğunu bilmiyoruz. Burada modelleme ile en ince ayrıntısına kadar hesaplayabilir.

Mesela: Yılının eski olması fiyatı düşürür diye düşünürüz ama km'si düşükse bu iki parametre bir arada değerlendirildiğinde aracın fiyatını artırır.

Burada bahsetmiş olduğumuz tüm kavramları modelleme tekniği yada algoritma ÇOKLU DOĞRULAMA REGRESYON MODELİ'dir.

Birçok farklı modelleme tekniği türü var: Ağaca dayalı, destek vektör makinaları, yapay sinir ağları vb. gibi. Hepsinin temeli ÇOKLU DOĞRULAMA REGRESYON MODELİ'dir.

Aralarındaki ilişkiyi modellediğimizde şöyle bir şey ortaya çıkacak. Gerekli matematiksel denklemlerin çözülmesi, optimizasyon tekniklerinin kullanılması sonucunda elimizde tahmini araç fiyatı diyerek, araç fiyatlarının tahminini üretecek olan bir fonksiyon ortaya çıktı.

## Modelleme



| Araç Fiyatı | KM     | Vites Türü | Hasar Durumu | Marka | Model |
|-------------|--------|------------|--------------|-------|-------|
| 10000       | 300000 | Manuel     | Evet         | A     | A1    |
| 54000       | 40000  | Otomatik   | Hayır        | A     | A2    |
| 46999       | 90000  | Manuel     | Evet         | B     | B1    |
| 89000       | 80000  | Otomatik   | Evet         | C     | C1    |
| 70000       | 78000  | Otomatik   | Evet         | B     | B2    |
| 50000       | 30000  | Manuel     | Hayır        | C     | C2    |
| 6000        | 600000 | Manuel     | Hayır        | C     | C3    |
| 68900       | 50000  | Otomatik   | Hayır        | B     | B2    |
| 12000       | 200000 | Manuel     | Hayır        | A     | A1    |

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \dots + b_p x_p$$

$$\text{Tahmini Araç Fiyatı} = 80000 - 0.2 * \text{KM} - 2500 * \text{Hasar Durumu} + \dots + 6000 * \text{Vites Türü}$$

Betalar veri setinin içerisinde öğrenecek olduğumuz değişkenlerin etki düzeylerini ve yönlerini belirtecek olan katsayılardır.



KM: 60000  
Hasar: Evet Var (1)  
Vites Türü: Otomatik (1)

$$\text{Tahmini Araç Fiyatı} = 80000 - 0.2 * \text{KM} - 2500 * \text{Hasar Durumu} + \dots + 6000 * \text{Vites Türü}$$

$$\text{Tahmini Araç Fiyatı} = 80000 - 0.2 * 60000 - 2500 * 1 + \dots + 6000 * 1$$

$$\text{Tahmini Araç Fiyatı} = 71500 \text{ TL}$$

Modeli kurduk. Kırmızılar öğrenilmiş model. Maviler verimizden elde etmiş olduğumuz değerler.

Km: 60000 olması negatif yönde etkiler – o yüzden.

Hasar durumu: 1(Evet hasar var) negatif yönde etkiler – o yüzden.

Vites türü: 1(Otomatik) pozitif yönde etkiler + o yüzden.

Bu şekilde tahmini araç fiyatı hesaplanmış olacaktır.

## Değerlendirme (Evaluation)

Bir model kurulduktan sonra değerlendirme işleminin yapılması ve test edilmesi gerekiyor.

Modeli değerlendirmek için modele zaten sonucunu bildiğimiz bir veri veririz. Bu gerçek değer ile tahmin edilen değeri karşılaştırıp bir model değerlendirme işlemi gerçekleştiririz.

### Değerlendirme

Araç fiyat tahmin modeli hikayesi



Gerçek değerler vs Tahmin Edilen Değerler

| Araç Fiyatı | KM    | Vites Türü | Hasar Durumu | Marka | Model |
|-------------|-------|------------|--------------|-------|-------|
| 73000       | 60000 | Otomatik   | Evet         | A     | A1    |

Tahmini Araç Fiyatı =  $80000 - 0,2 * KM - 2500 * Hasar Durumu + \dots + 6000 * Vites Türü$

Tahmin edilen fiyat: 71500

Gerçek fiyat: 73000

Bir Veri Bilimci olarak amacımız, tahminler sonucundaki gerçek değerler ile tahmin edilen değerler arasındaki farkları minimum yapacak şekilde algoritmaları çalıştırmak olacaktır.

NOT: Hata kareler ortalamasının karekökü veya hata kareler toplamı gibi işlemlerle aralarındaki farkı değerlendirip modelin ne kadar başarılı veya başarısız şeklinde bir değerlendirmede bulunmuş oluyoruz.

## Kullanıma Sokma (Deployment)

Modelin her adımı tamamlandıktan sonra modeli kullanıma alabiliriz ve web sitemizde yayına açabiliriz.

Bazen bu örneğimizde olduğu gibi canlı sistemlere entegrasyon şeklinde, bazen bir excel tablosu şeklinde, bazen de MySQL(veritabanı) tablosu şeklinde, bazen de bir rapor olarak gerçekleştirebiliriz.